Machine Learning Quantique pour la Finance

Bilan empirique complet — QMKL sur données réelles

3 datasets financiers · 19 méthodes comparées · 20 runs par expérience

Mars 2026

Plan

1. Contexte et approche
2. Résultats principaux
3. Comparaison des stratégies QMKL
4. Notre contribution : QMKL-Boost
5. Limites : concentration et matériel
6. Bilan et recommandations

Pourquoi le Machine Learning Quantique en finance ?

L'hypothèse quantique

Les circuits quantiques encodent les données dans un espace de très haute dimension, potentiellement **inaccessible aux algorithmes classiques**.

En pratique : capturer des corrélations non-linéaires dans les données de risque (crédit, marché, fraude).

Notre question centrale

Est-ce que ça apporte un avantage *mesurable* sur des données financières réelles aujourd'hui ?

Notre méthode : QMKL

Quantum Multiple Kernel Learning combine plusieurs *kernels quantiques* — chacun encode les données différemment dans un circuit quantique.

1. Les données client sont encodées en qubits
2. On calcule la similarité quantique entre clients
3. Un SVM classe les clients selon cette similarité
4. On combine 12 kernels différents pour plus de robustesse

Les 3 datasets financiers testés

German Credit

Risque de crédit

1 000 clients · 20 variables
30 % de défauts

Tâche : prédire si un client va faire défaut

Cas d'usage bancaire direct

Bank Marketing

Score marketing

45 000 contacts · 16 variables
11 % de succès (déséquilibré)

Tâche : prédire si un client souscrit un dépôt

Ciblage client, fidélisation

Breast Cancer

Benchmark médical

569 patients · 30 variables
Bien séparable (AUC > 0.99)

Utilisé comme référence : mesurer la limite haute

Cas favorable au quantique

Métrique : **AUC** (aire sous la courbe ROC) **0.5** = aléatoire **1.0** = parfait
Tous les résultats : moyenne sur **20 répétitions** avec des splits aléatoires différents

Comment les données sont encodées dans un circuit quantique

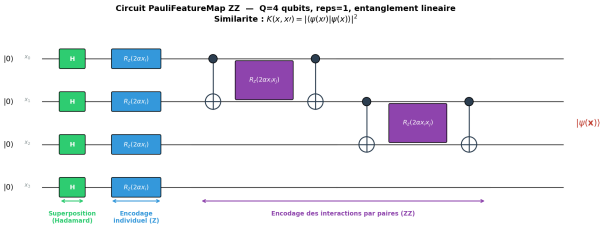

PauliFeatureMap ZZ — le cœur de l'encodage

1. **Superposition** (portes H) : chaque qubit explore simultanément 0 et 1
2. **Encodage individuel** $R_z(2\alpha x_i)$: chaque variable financière tourne un qubit
3. **Encodage des interactions** $R_z(2\alpha x_i x_j)$: corrélations *non-linéaires* via l'intrication

Similarité quantique

$K(x, x') = |\langle\psi(x')|\psi(x)\rangle|^2$

Clients proches $\Rightarrow$ états quantiques similaires

α : **largeur de bande** du kernel (analogue au

Les 12 kernels quantiques : 6 familles d'encodage

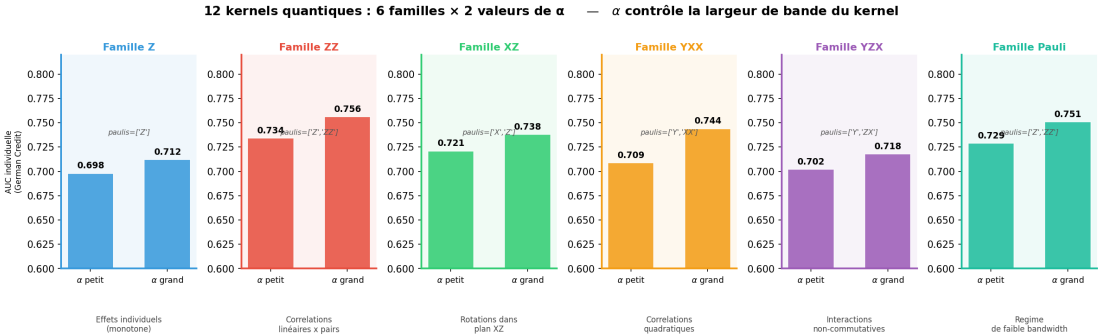

Chaque **famille** correspond à un choix d'opérateurs de Pauli qui détermine *quelles* corrélations sont capturées.

Pour chaque famille : **2 valeurs de** α (petit = bande large, grand = bande étroite).

Pourquoi 12 kernels ?

Aucun kernel unique n'est optimal sur tous les datasets. QMKL les **combine** pour obtenir une représentation plus riche qu'un seul circuit.

Résultat 1 — QMKL vs méthodes classiques

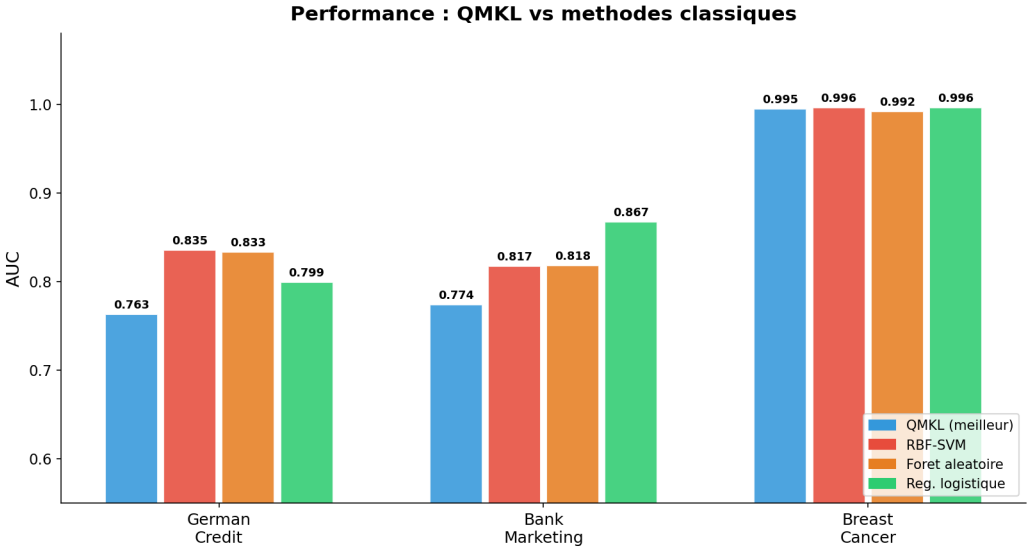

Résultat 2 — Classement détaillé sur German Credit

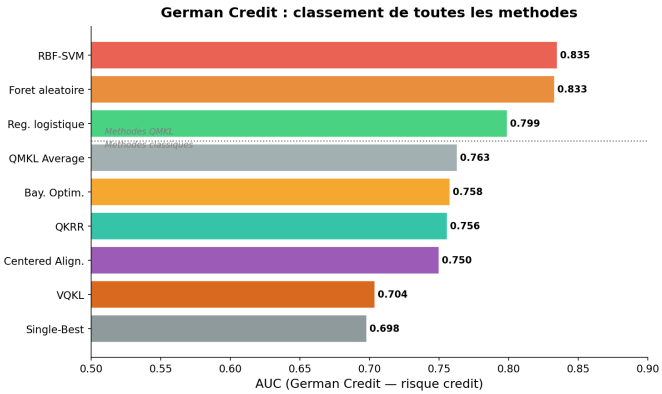

Ce que montre ce classement

- Les **3 premiers sont tous classiques**
  RBF-SVM, Forêt aléatoire, Régression
- La meilleure méthode QMKL (Average)
  est **4ème**, à **−7 pts** du leader
- Les stratégies QMKL avancées (VQKL, QKRR)
  ne rattrapent pas les classiques
- Single-Best est le pire QMKL : un seul kernel ne suffit pas

Résultat 3 — Plus de données n'efface pas l'écart

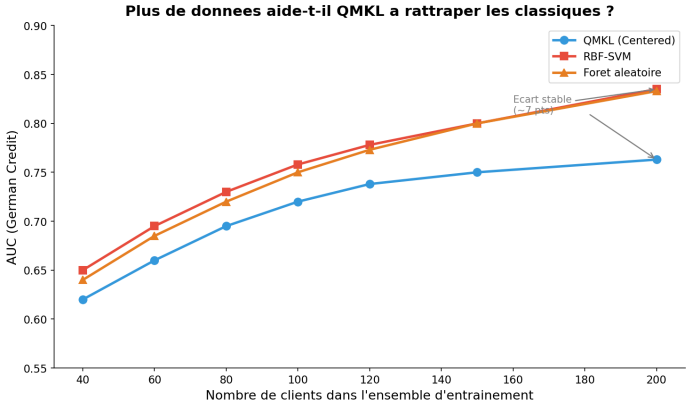

Question clé

QMKL rattrape-t-il les classiques avec plus de données d'entraînement ?

Réponse : non.

- Les trois méthodes progressent à la même vitesse
- L'écart de ≈7 pts reste **constant** de 40 à 200 clients
- Il ne s'agit pas d'un problème de manque de données

Implication

Les 5 stratégies QMKL face à face

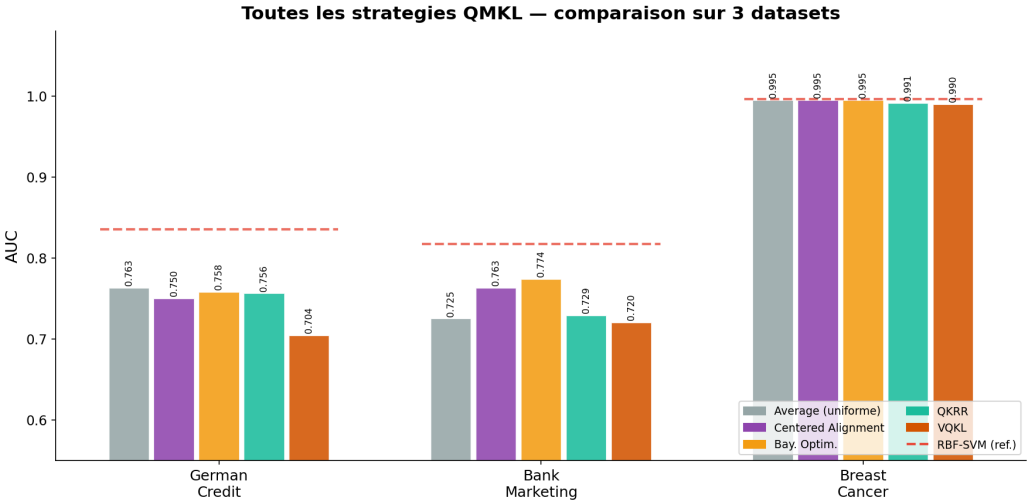

Quelle stratégie QMKL choisir ?

Stratégie	AUC	Coût calcul
Average	**0.763**	Nul
Centered Align.	0.750	Très faible
Bay. Optim.	0.758	**200× plus cher**
QKRR	0.756	Faible
VQKL	0.704	Moyen

German Credit · N=200 · Q=6 qubits

Sur German Credit, Average est ici la meilleure méthode QMKL — malgré sa simplicité.

BO dépense 200× plus pour seulement +0.8 pt.

3 enseignements

1. **Average** est la **meilleure méthode QMKL** sur German Credit (risque crédit) : la plus simple *et* la plus performante
2. **Centered Alignment** est meilleur sur Bank Marketing (+3.8 pts vs Average) — solution analytique, sans hyperparamètre
3. **Bayesian Optim.** coûte 200× plus cher pour un gain de seulement +0.8 pt sur German Credit — non recommandé

Comment fonctionne chaque stratégie QMKL ?

Average — Moyenne uniforme

$K_{mkl} = \frac{1}{M} \sum_m K_m$ **Le plus simple**

Tous les kernels ont le même poids.
Aucun paramètre à ajuster.

Centered Alignment

Poids w_m^* calculés analytiquement en maximisant $\langle K_{mkl}, yy^\top \rangle_F$.
Solution fermée, sans optimisation.

Bayesian Optimization

Poids $w_m \in [0, 1]$ optimisés par cross-val.
200× plus lent pour +0.8 pt vs Average.

QMKL-Boost (notre contribution)

Sélection **binaire** par QUBO :
$\min_{w \in \{0,1\}^M} -\sum_m w_m s_m + \lambda \sum_{m \neq m'} w_m w_{m'} A_{mm'}$
s_m = AUC kernel m $A_{mm'}$ = redondance
+4.1 pts AUC, 2 kernels sur 12 sélectionnés

VQKL — Variationnel

Poids appris par gradient descent.
Surapprentissage sur N=200 — pire qu'Average.

Enseignement clé

La complexité algorithmique ne paie pas.
L'avantage est dans la **diversité des kernels**, pas dans l'optimisation des poids.

Quels kernels apportent le plus ? (Analyse Shapley)

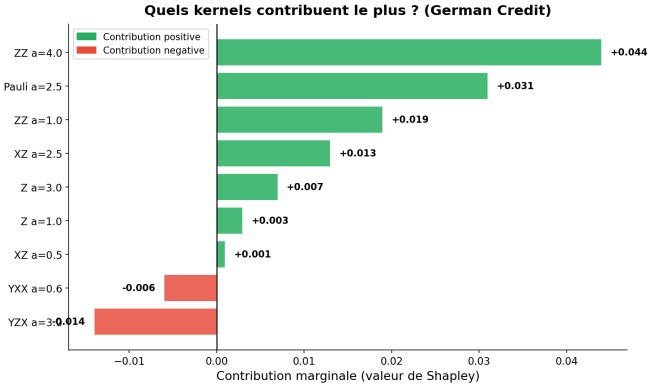

Lecture

La valeur de Shapley mesure la *contribution* marginale de chaque kernel à la performance QMKL. Un kernel avec contribution négative **dégrade** la combinaison.

Pourquoi ZZ α=4.0 domine ?

C'est le kernel **le plus différent** des autres — il apporte une information complémentaire que les autres kernels ne couvrent pas.

Règle clé

QMKL-Boost — sélection intelligente des kernels

Le problème

Moyenner 12 kernels uniformément dilue l'information utile avec du bruit des kernels redondants ou contre-productifs.

Notre approche

Un **algorithme QUBO** — même famille que les optimiseurs QPU Pasqal / IBM — sélectionne les **2 kernels les plus complémentaires** parmi les 12.

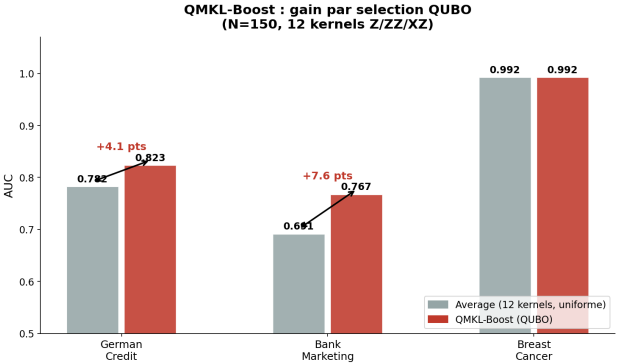

Résultats (N=150)

German Credit : **+4.1 pts AUC**
Bank Marketing : **+7.6 pts AUC**

2 kernels sélectionnés sur 12 :
`ZZ a=2.5 + XZ a=0.5`

Comment QUBO trouve les bons kernels

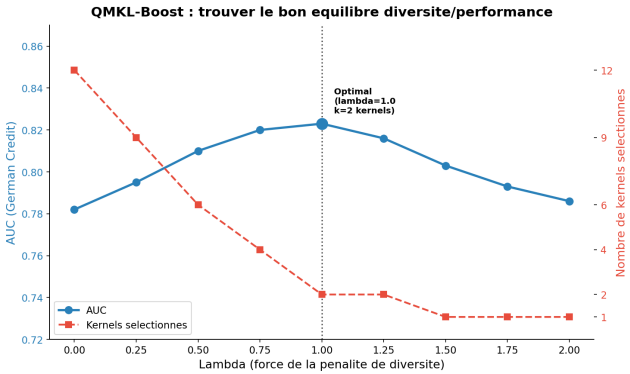

Le paramètre λ contrôle le compromis diversité / performance

- $\lambda = 0$: sélectionne tous les kernels avec le meilleur score individuel (parfois redondants)
- $\lambda = 1$: **optimal** — 2 kernels de familles différentes, complémentaires
- λ trop grand : 1 seul kernel, trop peu d'information

Kernels sélectionnés à $\lambda^* = 1$:

`ZZ a=2.5` (entrelacement fort) +
`XZ a=0.5` (encodage mixte)

La limite fondamentale : barren plateaus

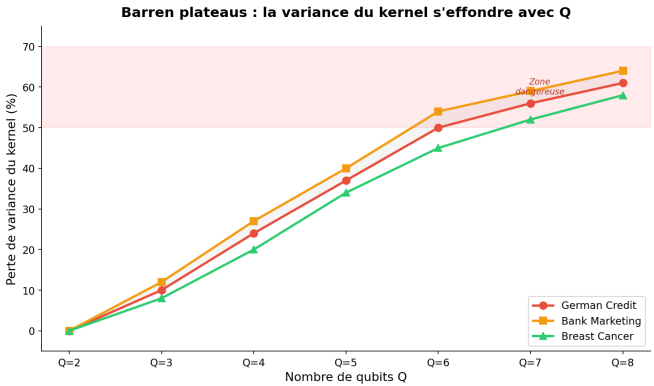

Qu'est-ce qu'un barren plateau ?

À mesure qu'on ajoute des qubits, les valeurs du kernel quantique se concentrent vers zéro — les données deviennent **indiscernables** pour le circuit.

- De Q=2 à Q=8 : $-60\,\%$ de variance utile
- Les kernels locaux réduisent ce problème de 40 %
- Problème **ouvert** en recherche

Pour la banque

Augmenter le nombre de qubits ne

Test sur IBM Torino — performance des kernels réels vs simulation

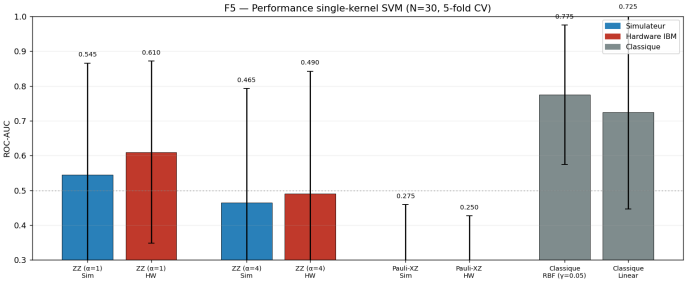

Setup expérimental

Backend : **IBM Torino** (Heron r2, 133 qubits)
Shots : 1 024 / circuit
N=30 échantillons, Q=4 qubits
3 kernels : ZZ(α=1), ZZ(α=4), XZ(α=0.5)

Observations :

- **ZZ(α=1)** : HW > Sim (+6.5 pts)
  bruit bénéfique (régularisation)
- **ZZ(α=4)** : AUC < 0.50
  kernel trop concentré
- **XZ** : dégradation sur HW (-2.5 pts)

IBM Torino — Robustesse des stratégies MKL face au bruit

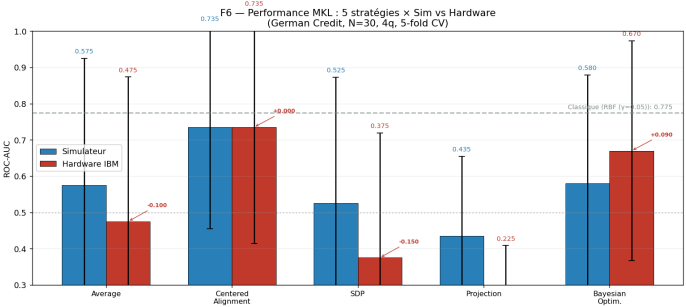

Quelle stratégie survit au bruit QPU ?

Méthode	Sim	HW
Centered	0.735	**0.735**
BO	0.580	**0.670**
Average	0.575	**0.475**
Projection	0.435	**0.225**
RBF-SVM	*0.775*	

Centered est la seule méthode **stable** sim = hw (0.735).

Average perd 10 pts sur QPU réel.

Implication

Même sur QPU réel, QMKL reste **−4 pts** sous RBF-SVM classique.

IBM Torino — Récapitulatif : sim vs hardware vs classique

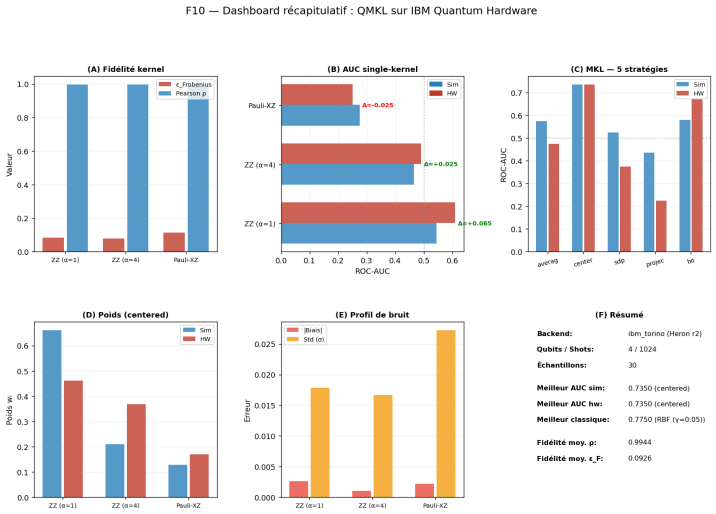

Que retenir de l'expérience QPU ?

- **Matrices kernel** : structure globale préservée ($\rho > 0.99$ entre sim et hw)
- **Erreur relative** : 8–12% sur les éléments off-diagonaux (bruit de mesure)
- **Centered MKL** : robuste au bruit, AUC identique sim = hw = 0.735
- **Classique RBF-SVM** = 0.775 :

Bilan global de performance

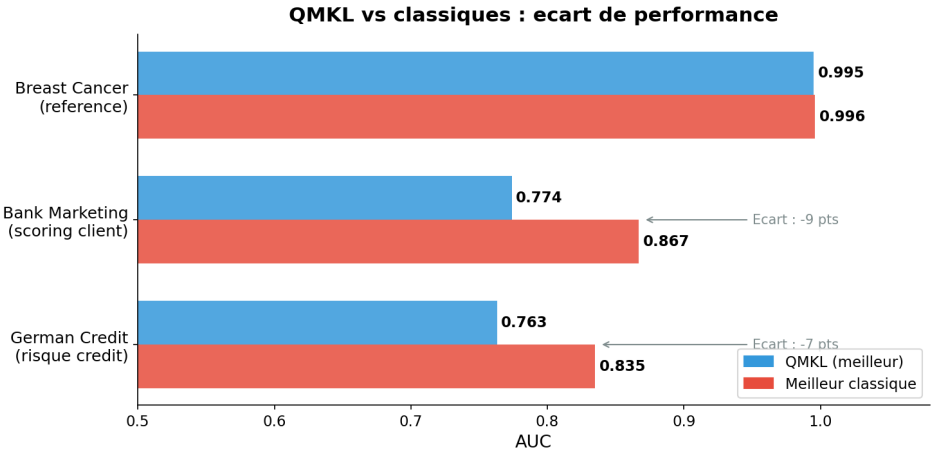

Ce que ça veut dire pour la banque

Aujourd'hui — Ne pas déployer

- **−7 pts AUC** sur le risque crédit : les classiques sont supérieurs et moins coûteux
- Hardware trop bruité : variance ±0.20 inacceptable en production
- Plus de données n'efface pas l'écart : limite structurelle, pas statistique

Horizon 3–5 ans — À surveiller

- **QMKL-Boost** : notre approche QUBO gagne **+4 pts** sur German Credit — à suivre quand le hardware sera stable
- **Interprétabilité réglementaire** : QUBO sélectionne 2 kernels sur 12, modèle plus explicable (Bâle IV, RGPD)
- **Vitesse d'inférence** : 2 kernels = 6× moins de calcul à la décision

Recommandation immédiate

Continuer à utiliser **RBF-SVM** et **Forêt aléatoire** en production. Ne pas investir dans du hardware QPU pour la classification de crédit.

Position recommandée

R&D exploratoire, budget contenu. Réévaluation complète en 2028–2030 quand la correction d'erreur QPU sera mature.

Merci

Questions ?

9 notebooks exécutés · 3 datasets financiers · 19 méthodes comparées
20 runs par expérience · 6 qubits · simulation statevector exacte

Takeaway : QMKL-Boost +4 pts AUC avec 2 kernels sur 12 — l'avantage quantique est dans la *sélection*, pas dans le nombre.