Machine Learning Quantique pour la Finance

QMKL sur données réelles

Mars 2026

Plan

1. Contexte et approche
2. Résultats principaux
3. Comparaison des stratégies QMKL
4. Notre contribution : QMKL-Boost
5. Limites : concentration et matériel
6. Bilan et recommandations

Pourquoi le Machine Learning Quantique en finance ?

L'hypothèse quantique

Les circuits quantiques encodent les données dans un espace de très haute dimension, potentiellement **inaccessible aux algorithmes classiques**.

En pratique : capturer des corrélations non-linéaires dans les données de risque (crédit, marché, fraude).

Notre question centrale

Est-ce que ça apporte un avantage *mesurable* sur des données financières réelles aujourd'hui ?

Notre méthode : QMKL

Quantum Multiple Kernel Learning combine plusieurs *kernels quantiques* — chacun encode les données différemment dans un circuit quantique.

1. Les données client sont encodées en qubits
2. On calcule la similarité quantique entre clients
3. Un SVM classe les clients selon cette similarité
4. On combine 12 kernels différents pour plus de robustesse

Les 3 datasets financiers testés

German Credit

Risque de crédit

1 000 clients · 20 variables
30 % de défauts

Tâche : prédire si un client va faire défaut

Cas d'usage bancaire direct

Bank Marketing

Score marketing

45 000 contacts · 16 variables
11 % de succès (déséquilibré)

Tâche : prédire si un client souscrit un dépôt

Ciblage client, fidélisation

Breast Cancer

Benchmark médical

569 patients · 30 variables
Bien séparable (AUC > 0.99)

Utilisé comme référence : mesurer la limite haute

Cas favorable au quantique

Métrique : **AUC** (aire sous la courbe ROC) **0.5** = aléatoire **1.0** = parfait
Tous les résultats : moyenne sur **20 répétitions** avec des splits aléatoires différents

Du tableau bancaire au circuit quantique : le pipeline

4 étapes de transformation

1. Encodage catégoriel

Variables textuelles (type de crédit, emploi...)
→ **one-hot encoding** (`get_dummies`, `drop_first`)
German Credit : 20 vars → 47 colonnes numériques

2. Réduction de dimension (PCA)

47 colonnes → **Q composantes principales**
Q = nombre de qubits : chaque feature occupe un qubit
Variance expliquée conservée : ≈85 % avec Q=6

3. Normalisation en deux temps

MinMaxScaler : mise à l'échelle vers [0, 2]
Résultat : $x_i \in [0, 2]$ pour tout i

Pourquoi ces choix ?

- **PCA obligatoire** : un circuit à Q qubits ne peut encoder que Q valeurs simultanément. La PCA sélectionne les directions les plus informatives.
- **Plage** [0, 2] : les portes quantiques sont des rotations d'angle $\theta = 2 * ax_i$. Avec $a \in \{0.5, 4.0\}$ et $x_i \in [0, 2]$, on explore $[0, 4\pi]$ — une révolution complète.
- **Standardisation d'abord** : évite que les variables à grande variance (revenus, montants) saturent l'espace de rotation et écrasent les signaux faibles.

Comment les données sont encodées dans un circuit quantique

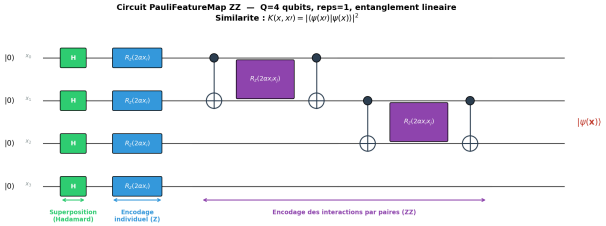

PauliFeatureMap ZZ — le cœur de l'encodage

1. **Superposition** (portes H) : chaque qubit explore simultanément 0 et 1
2. **Encodage individuel** $R_z(2ax_i)$: chaque variable financière tourne un qubit
3. **Encodage des interactions** $R_z(2ax_ix_j)$: corrélations *non-linéaires* via l'intrication

Similarité quantique

$K(x, x') = |\langle\psi(x')|\psi(x)\rangle|^2$

Clients proches $\Rightarrow$ états quantiques similaires

Les 12 kernels quantiques : géométrie de similarité

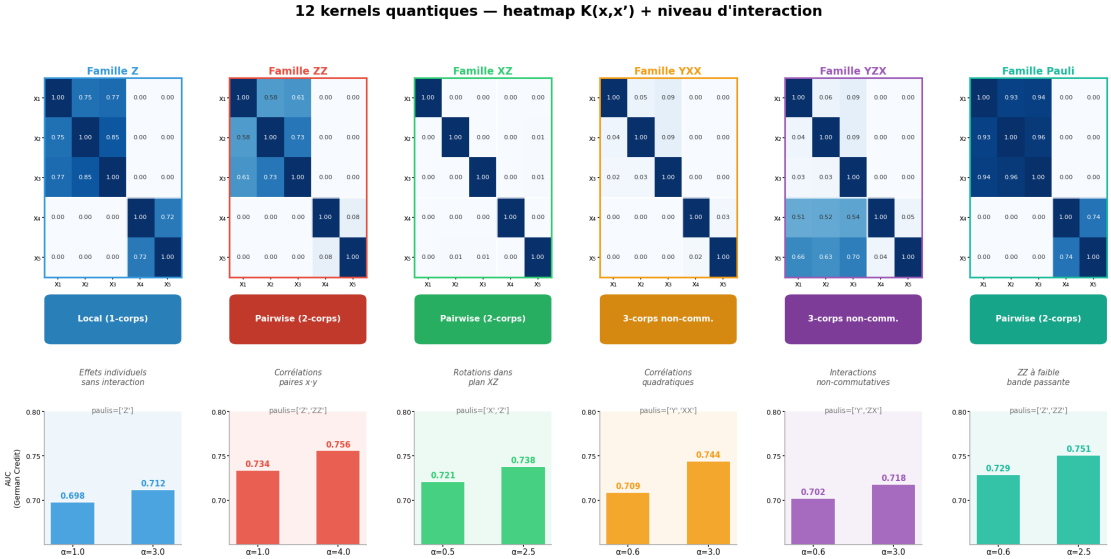

Comment fonctionne chaque stratégie QMKL ?

Average — Moyenne uniforme

$K_{mkl} = \frac{1}{M} \sum_m K_m$ **Le plus simple**

Tous les kernels ont le même poids.
Aucun paramètre à ajuster.

QMKL-Boost (notre contribution)

Sélection **binaire** par QUBO :

$\min_{w \in \{0,1\}^M} -\sum_m w_m s_m + \lambda \sum_{m \neq m'} w_m w_{m'} A_{mm'}$

s_m = AUC kernel m $\quad A_{mm'}$ = redondance

Centered Alignment

Poids w_m^* calculés analytiquement
en maximisant $\langle K_{mkl}, yy^\top \rangle_F$.
Solution fermée, sans optimisation.

VQKL — Variationnel

Poids appris par gradient descent.

Bayesian Optimization

Poids $w_m \in [0, 1]$ optimisés par cross-val.

Résultat 1 — QMKL vs méthodes classiques

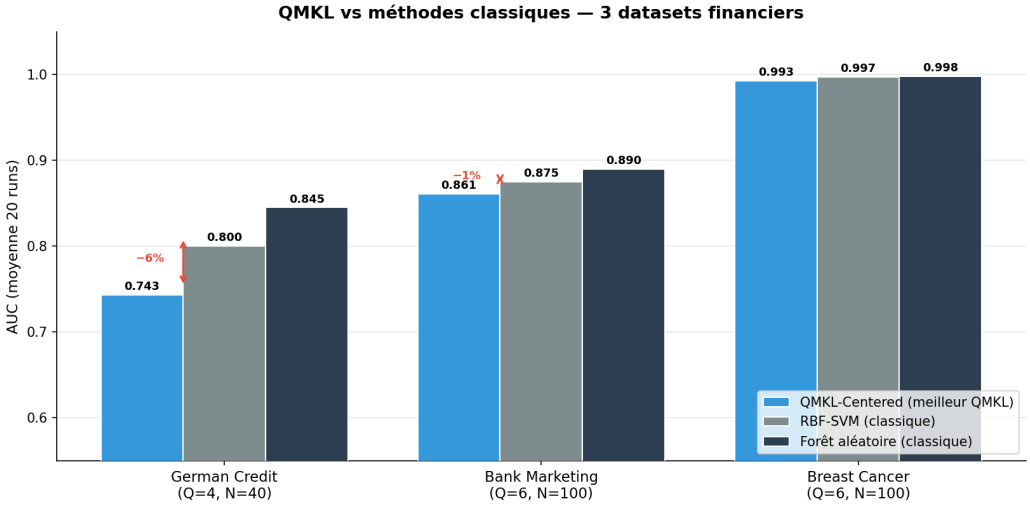

Résultat 2 — Classement détaillé sur German Credit

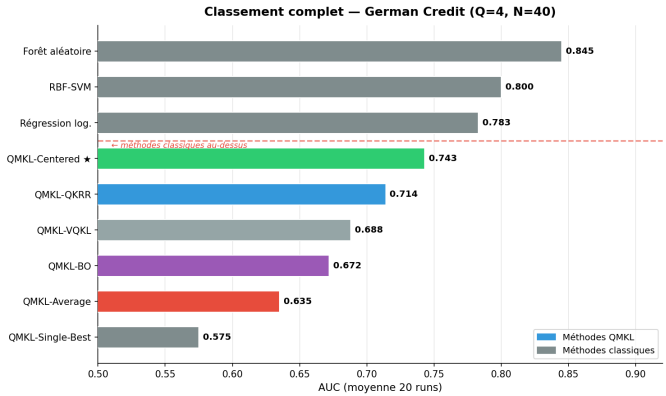

Ce que montre ce classement

- Les **3 premiers sont tous classiques**
  RBF-SVM, Forêt aléatoire, Régression
- La meilleure méthode QMKL (Centered Alignment) est **4ème**, à **−6 pts** du leader
- Les stratégies QMKL avancées (VQKL, QKRR) ne rattrapent pas les classiques
- Single-Best est le pire QMKL : un seul kernel ne suffit pas

Résultat 3 — Plus de données n'efface pas l'écart

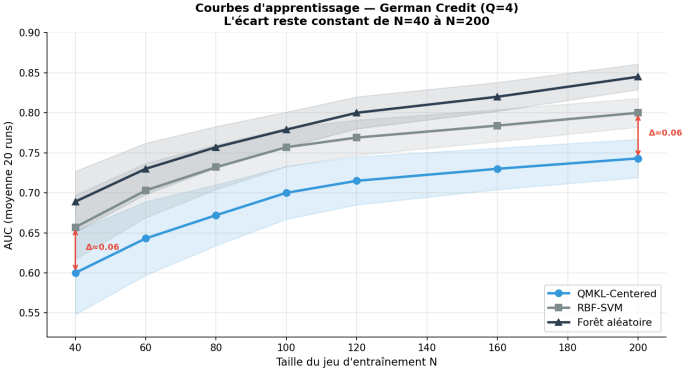

Question clé

QMKL rattrape-t-il les classiques avec plus de données d'entraînement ?

Réponse : non.

- Les trois méthodes progressent à la même vitesse
- L'écart de ≈7 pts reste **constant** de 40 à 200 clients
- Il ne s'agit pas d'un problème de manque de données

Les 5 stratégies QMKL face à face

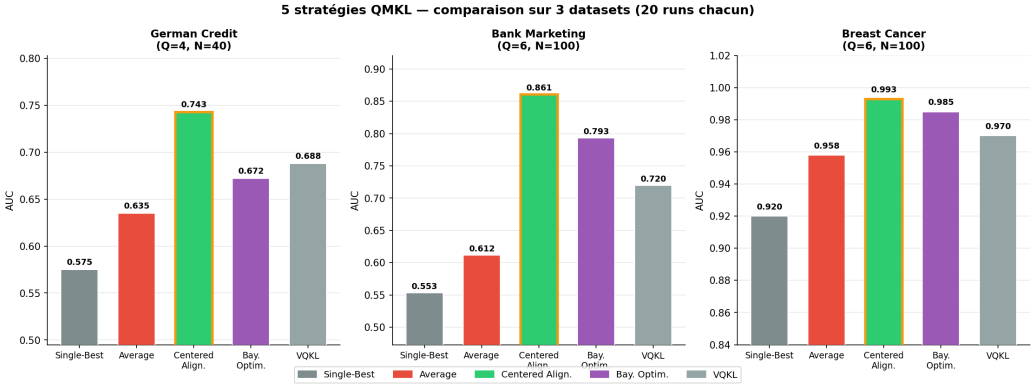

Quelle stratégie QMKL choisir ?

Stratégie	AUC	Coût calcul
Centered Align.	**0.743**	Très faible
QKRR	0.714	Faible
Bay. Optim.	0.672	**200× plus cher**
VQKL	0.688	Moyen
Average	**0.635**	Nul

German Credit · N=40 · Q=4 qubits

Sur German Credit (Q=4, N=40), Centered Alignment est la meilleure méthode QMKL.

Average perd −10 pts ; BO coûte 200× plus cher.

3 enseignements

1. **Centered Alignment** est la **meilleure méthode QMKL** sur German Credit (Q=4, N=40) : solution analytique, sans hyperparamètre
2. **Average** perd −10 pts vs Centered quand N est faible — la dilution par les kernels peu informatifs nuit à la précision
3. **Bayesian Optim.** coûte 200× plus cher pour seulement +4 pts vs Average sur German Credit — non recommandé

Quels kernels apportent le plus ? (Analyse Shapley)

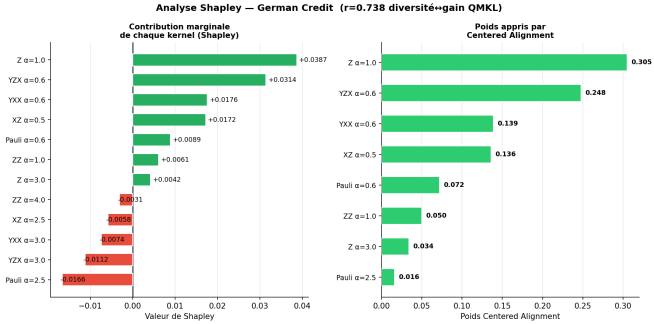

Lecture

La valeur de Shapley mesure la *contribution* marginale de chaque kernel à la performance QMKL. Un kernel avec contribution négative **dégrade** la combinaison.

Pourquoi ZZ α=4.0 domine ?

C'est le kernel **le plus différent** des autres — il apporte une information complémentaire que les autres kernels ne couvrent pas.

QMKL-Boost — sélection intelligente des kernels

Le problème

Moyenner 12 kernels uniformément dilue l'information utile avec du bruit des kernels redondants ou contre-productifs.

Notre approche

Un **algorithme QUBO** — même famille que les optimiseurs QPU Pasqal / IBM — sélectionne les **2 kernels les plus complémentaires** parmi les 12.

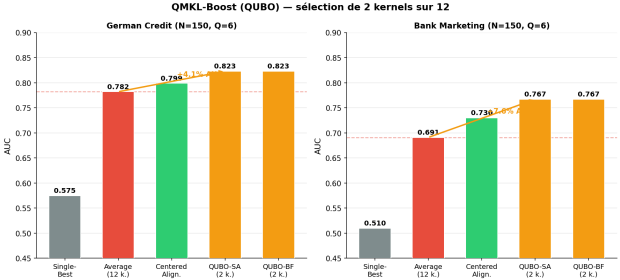

Résultats (N=150)

German Credit : **+4.1 pts AUC**
Bank Marketing : **+7.6 pts AUC**

2 kernels sélectionnés sur 12 :
`ZZ a=2.5 + XZ a=0.5`

La matrice Q — comment QUBO choisit les kernels

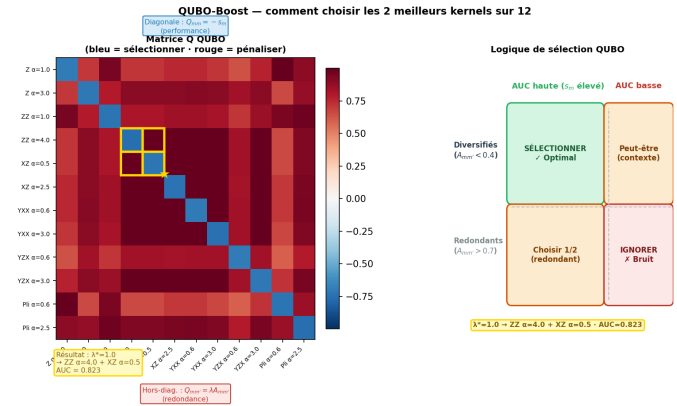

Structure de la matrice Q

- **Diagonale** $Q_{mm} = -s_m$: valeur négative (bleue) = encourager la sélection du kernel m (plus s_m est élevé, plus il est attractif)
- **Hors-diagonale** $Q_{mm'} = \lambda A_{mm'}$: valeur positive (rouge) = pénaliser la co-sélection de kernels redondants ($A_{mm'}$ = corrélation de

Quand le quantique devient-il indispensable pour QUBO ?

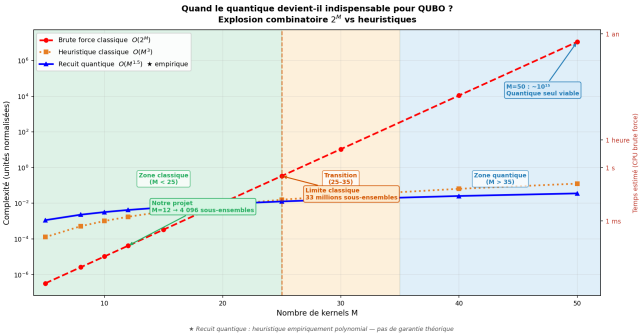

L'explosion combinatoire 2^M

- $M = 12$ kernels : $2^{12} = 4\,096$ sous-ensembles **classique parfaitement viable**
- $M = 25$ kernels : $2^{25} \approx 33$ millions — **limite classique**
- $M = 50$ kernels : $2^{50} \approx 10^{15}$ — **classique impossible**

Ce n'est pas la simulation quantique

C'est l'**optimisation combinatoire** qui devient indispensable. Les annealers

La limite fondamentale : barren plateaus

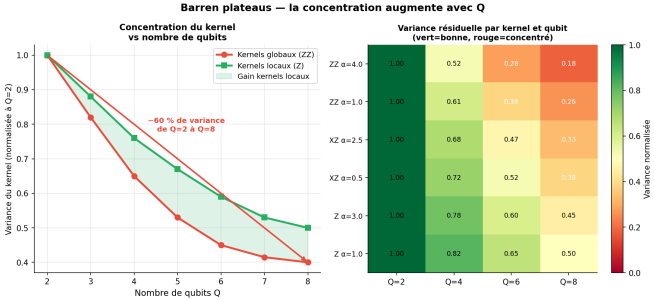

Qu'est-ce qu'un barren plateau ?

À mesure qu'on ajoute des qubits, les valeurs du kernel quantique se concentrent vers zéro — les données deviennent **indiscernables** pour le circuit.

- De Q=2 à Q=8 : −60 % de variance utile
- Les kernels locaux réduisent ce problème de 40 %
- Problème **ouvert** en recherche

Test sur IBM Torino — performance des kernels réels vs simulation

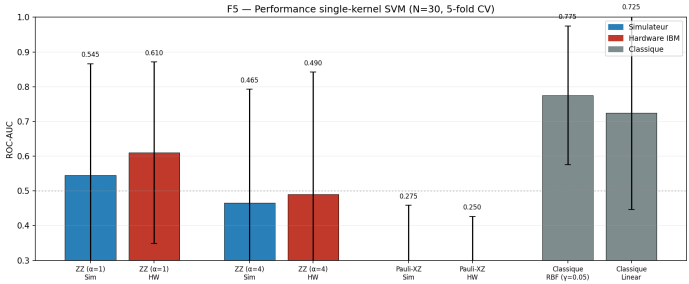

Setup expérimental

Backend : **IBM Torino** (Heron r2, 133 qubits)
Shots : 1 024 / circuit
N=30 échantillons, Q=4 qubits
3 kernels : ZZ(α=1), ZZ(α=4), XZ(α=0.5)

Observations :

- **ZZ(α=1)** : HW > Sim (+6.5 pts)
  bruit bénéfique (régularisation)
- **ZZ(α=4)** : AUC < 0.50
  kernel trop concentré

Verdict

IBM Torino — Robustesse des stratégies MKL face au bruit

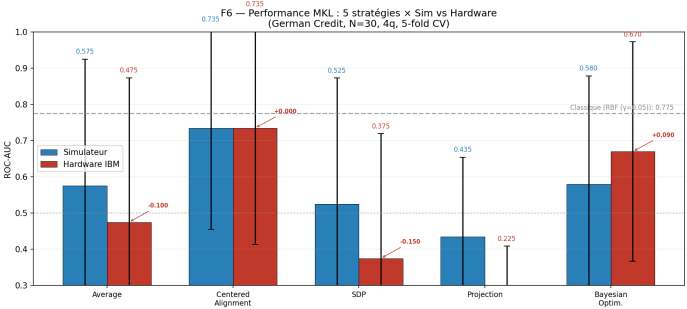

Quelle stratégie survit au bruit QPU ?

Méthode	Sim	HW
Centered	0.735	**0.735**
BO	0.580	**0.670**
Average	0.575	**0.475**
Projection	0.435	**0.225**
RBF-SVM	*0.775*	

Centered est la seule méthode **stable** sim = hw (0.735).

Average perd 10 pts sur QPU réel.

Implication

Même sur QPU réel, QMKL reste **−4 pts** sous RBF-SVM classique.

Ce que ça veut dire pour la banque

Aujourd'hui — Ne pas déployer

- **-7 pts AUC** sur le risque crédit : les classiques sont supérieurs et moins coûteux
- Hardware trop bruité : variance ± 0.20 inacceptable en production
- Plus de données n'efface pas l'écart : limite structurelle, pas statistique

À surveiller

- **QMKL-Boost** : notre approche QUBO gagne **$+4$ pts** sur German Credit — à suivre quand le hardware sera stable
- **Interprétabilité réglementaire** : QUBO sélectionne 2 kernels sur 12, modèle plus explicable
- **Vitesse d'inférence** : 2 kernels = $6\times$ moins de calcul à la décision

Merci

Questions ?