# Quantum Multiple Kernel Learning

## Évaluation Empirique et Assignation QUBO de Features

Rapport académique

Projet-QMKL-Finance (v1) · Projet-QMKL-v2

---

| | |
|---|---|
| **Cadre :** | Projet académique — Informatique Quantique Appliquée |
| **Outils :** | Qiskit 1.x, scikit-learn, IBM Quantum Open Plan |
| **Matériel :** | IBM Torino (Heron r2, 133 qubits) |
| **Date :** | Avril 2025 |

**Résumé**

Ce rapport présente deux projets successifs explorant le *Quantum Multiple Kernel Learning* (QMKL). Le premier projet (QMKL-Finance, v1) conduit une évaluation empirique systématique de douze noyaux quantiques combinés selon cinq stratégies MKL, sur trois jeux de données incluant des données financières (German Credit, Bank Marketing) et un benchmark médical (Breast Cancer). Le second (QMKL-v2) propose une formulation QUBO originale permettant d'assigner optimalement des features à des noyaux quantiques et fournit une preuve de concept sur Breast Cancer, avec IBM Torino comme banc d'essai hardware. L'extension aux données macroéconomiques FRED reste une perspective future. Les résultats, bien que mitigés vis-à-vis des classifieurs classiques, permettent de documenter avec précision les phénomènes limitants — notamment les *barren plateaus* — et de délimiter les régimes pour lesquels l'approche quantique devient pertinente.

# Table des matières

**1 Introduction** **3**
1.1 Contexte et motivation . . . 3
1.2 Problématiques des deux projets . . . 3
1.3 Plan du rapport . . . 3

**2 Fondements Théoriques** **4**
2.1 Noyaux quantiques . . . 4
2.1.1 Encodage dans un espace de Hilbert quantique . . . 4
2.1.2 Noyau de fidélité . . . 4
2.1.3 Noyau projeté . . . 4
2.2 Familles d'encodage utilisées . . . 4
2.2.1 ZFeatureMap . . . 4
2.2.2 ZZFeatureMap . . . 5
2.3 Multiple Kernel Learning . . . 5
2.3.1 Combinaison linéaire convexe . . . 5
2.3.2 Alignement centré . . . 5
2.3.3 Programme semi-défini (SDP) . . . 5
2.3.4 Optimisation bayésienne . . . 6
2.4 Barren Plateaus . . . 6
2.5 Formulation QUBO pour l'assignation de features . . . 6
2.5.1 Problème d'assignation . . . 6
2.5.2 Formulation QUBO (Formulation C) . . . 7
2.5.3 Conversion en Hamiltonien d'Ising . . . 7
2.5.4 QAOA . . . 7

**3 Projet V1 — QMKL-Finance** **7**
3.1 Bibliothèque de noyaux . . . 7
3.2 Stratégies MKL comparées . . . 8
3.3 Jeux de données . . . 8
3.4 Résultats . . . 9
3.5 Analyses complémentaires . . . 10
3.6 Facteurs limitants identifiés . . . 10

**4 Assignation Optimale de Features par QUBO** **10**
4.1 Motivation . . . 10
4.2 Jeu de données . . . 11
4.3 Noyaux analytiques . . . 12
4.4 Solveurs QUBO . . . 12
4.5 Optimisation variationnelle dans QAOA . . . 12
4.5.1 De la matrice QUBO à l'Hamiltonien de coût $H_C$ . . . 12
4.5.2 L'ansatz QAOA et la boucle d'optimisation . . . 12
4.5.3 Pourquoi COBYLA plutôt que la descente de gradient ? . . . 13
4.5.4 Déroulement de la boucle itérative . . . 13
4.6 Étude empirique NB01 — Barren Plateaus . . . 14
4.7 Étude empirique NB02 — Croisement de complexité . . . 15
4.8 Expérience sur hardware IBM Torino . . . 15
4.8.1 Configuration . . . 15

4.8.2 Obstacles techniques rencontrés . . . . . 15
4.8.3 Données récupérées . . . . . 16
4.9 Résultats comparatifs . . . . . 16

**5 Discussion** **17**
5.1 Quand l'avantage quantique se manifeste-t-il ? . . . . . 17
5.2 Valeur des résultats négatifs . . . . . 17
5.3 Scalabilité et portée de l'assignation QUBO . . . . . 18
5.4 Bilan comparatif V1 / V2 . . . . . 19

**6 Conclusion** **19**

# 1 Introduction

## 1.1 Contexte et motivation

Le Machine Learning Quantique (QML) suscite un intérêt croissant en raison de sa capacité théorique à exploiter des espaces de représentation exponentiellement plus grands que ceux accessibles à un calculateur classique [1, 2]. Parmi les approches QML, les *noyaux quantiques* occupent une place particulière : ils s'inscrivent dans le cadre bien établi des Machines à Vecteurs de Support (SVM) tout en bénéficiant de la richesse des espaces de Hilbert quantiques [3].

Les données financières constituent un terrain d'expérimentation pertinent, bien que leur adéquation avec le QMKL reste à démontrer empiriquement (voir Section 3). Leur haute dimensionnalité (20 à 30 indicateurs macroéconomiques ou caractéristiques d'emprunteurs), leurs corrélations non linéaires complexes et leur faible rapport signal/bruit les rendent a priori susceptibles de profiter d'encodages dans des espaces de grande dimension [10]. De surcroît, les problèmes de classification binaire qu'elles induisent — prédiction de récession, évaluation du risque de crédit — sont formellement bien définis et disposent de métriques d'évaluation standards.

## 1.2 Problématiques des deux projets

**Projet v1 — QMKL-Finance.** La question directrice est la suivante : la combinaison de multiples noyaux quantiques hétérogènes améliore-t-elle les performances de classification par rapport à (i) un noyau quantique unique et (ii) les meilleurs classifieurs classiques de référence ? Cinq stratégies de combinaison sont comparées sur trois jeux de données.

**Projet v2 — QMKL-v2.** Le phénomène des *barren plateaus* (confirmé empiriquement en Section 4.6) impose de limiter chaque noyau à $Q \leq 6$ qubits environ. Pour un ensemble de $d = 20$–$30$ features, toute réduction globale par ACP entraîne une perte d'information. La question devient alors : comment assigner *optimalement* des sous-ensembles de features aux différents noyaux, de façon à couvrir l'espace des variables sans chevauchement redondant ? Ce problème est formulé comme un QUBO et attaqué via l'algorithme QAOA, ce qui soulève une seconde question : à quel régime de taille de problème le recours à un ordinateur quantique réel devient-il nécessaire ?

## 1.3 Plan du rapport

La section 2 établit les fondements théoriques communs aux deux projets. Les sections 3 et 4 décrivent respectivement les architectures, expériences et résultats de chaque projet. La section 5 met en perspective les deux approches et discute les conditions d'émergence d'un avantage quantique. La section 6 conclut et propose des perspectives.

# 2 Fondements Théoriques

## 2.1 Noyaux quantiques

### 2.1.1 Encodage dans un espace de Hilbert quantique

Un circuit quantique paramétré $U_\phi(\boldsymbol{x})$ appliqué à l'état initial $|\mathbf{0}\rangle^{\otimes Q}$ réalise une application

$$\phi : \boldsymbol{x} \in \mathbb{R}^Q \longmapsto |\psi(\boldsymbol{x})\rangle = U_\phi(\boldsymbol{x})\,|\mathbf{0}\rangle \in \mathcal{H}, \tag{1}$$

où $\mathcal{H} = (\mathbb{C}^2)^{\otimes Q}$ est un espace de Hilbert de dimension $2^Q$. La richesse de cet espace croît exponentiellement avec le nombre de qubits $Q$, ce qui constitue la source d'expressivité principale des noyaux quantiques.

### 2.1.2 Noyau de fidélité

**Définition 2.1** (Noyau de fidélité)**.** *Le* noyau de fidélité *associé à l'encodage $U_\phi$ est défini par*

$$K_{\text{fid}}(\boldsymbol{x}, \boldsymbol{x}') = \left|\langle\psi(\boldsymbol{x}')|\psi(\boldsymbol{x})\rangle\right|^2 = \left|\langle\mathbf{0}|\,U_\phi^\dagger(\boldsymbol{x}')\,U_\phi(\boldsymbol{x})\,|\mathbf{0}\rangle\right|^2. \tag{2}$$

Ce noyau est valide au sens de Mercer (symétrique, semi-défini positif) et s'estime sur circuit quantique par la probabilité de mesurer $|\mathbf{0}\rangle$ après l'application du circuit $U_\phi^\dagger(\boldsymbol{x}')U_\phi(\boldsymbol{x})$. Sa complexité de calcul est $O(N^2 \cdot \text{shots})$ pour une matrice de $N$ exemples.

### 2.1.3 Noyau projeté

Le *Projected Quantum Kernel* (PQK) [9] contourne la concentration exponentielle en réduisant l'état quantique à ses matrices densité mono-qubit. Pour chaque qubit $k$, on définit $\rho_k(\boldsymbol{x}) = \text{Tr}_{\neq k}|\psi(\boldsymbol{x})\rangle\langle\psi(\boldsymbol{x})|$, puis on pose :

$$K_{\text{proj}}(\boldsymbol{x}, \boldsymbol{x}') = \exp\left(-\gamma \sum_{k=0}^{Q-1} \left\|\rho_k(\boldsymbol{x}) - \rho_k(\boldsymbol{x}')\right\|_F^2\right). \tag{3}$$

Cette formulation correspond à un noyau RBF appliqué aux distances de Frobenius entre matrices densité réduites.

## 2.2 Familles d'encodage utilisées

### 2.2.1 ZFeatureMap

L'encodage local $Z$ prépare d'abord l'état $|+\rangle^{\otimes Q}$ par des portes Hadamard, puis applique des rotations mono-qubit sans intrication :

$$U_Z(\boldsymbol{x}) = \bigotimes_{k=0}^{Q-1} R_Z(2\alpha\, x_k) \cdot H, \tag{4}$$

où $\alpha > 0$ est un hyperparamètre de résolution et $H$ est la porte Hadamard. Le noyau de fidélité correspondant admet la forme analytique fermée

$$K_Z(\boldsymbol{x}, \boldsymbol{x}') = \prod_{k=0}^{Q-1} \cos^2\!\big(\alpha(x_k - x_k')\big), \tag{5}$$

obtenue en calculant $|\langle+|R_Z^\dagger(2\alpha x_k')R_Z(2\alpha x_k)|+\rangle|^2 = \cos^2(\alpha(x_k - x_k'))$.

### 2.2.2 ZZFeatureMap

L'encodage $ZZ$ ajoute une couche d'intrication linéaire entre qubits voisins :

$$U_{ZZ}(\boldsymbol{x}) = \left( \prod_{k=0}^{Q-2} \mathrm{CX}_{k,k+1} \cdot R_Z\big(\alpha\,(x_k - x_{k+1})^2\big) \cdot \mathrm{CX}_{k,k+1} \right) \cdot U_Z(\boldsymbol{x}). \tag{6}$$

Le noyau de fidélité associé capture des interactions de second ordre entre features et s'écrit :

$$K_{ZZ}(\boldsymbol{x}, \boldsymbol{x}') = K_Z(\boldsymbol{x}, \boldsymbol{x}') \cdot \prod_{k<l} \cos^2\big(\alpha(x_k x_l - x'_k x'_l)\big). \tag{7}$$

Des encodages plus riches (XZ, YXX, YZX) impliquant des portes Pauli supplémentaires et deux répétitions ont également été explorés en v1 (Section 3.1).

## 2.3 Multiple Kernel Learning

### 2.3.1 Combinaison linéaire convexe

Étant donnée une famille de $M$ noyaux $\{K_m\}_{m=1}^{M}$, le Multiple Kernel Learning définit le noyau composite

$$K_{\mathrm{comb}}(\boldsymbol{x}, \boldsymbol{x}') = \sum_{m=1}^{M} w_m\, K_m(\boldsymbol{x}, \boldsymbol{x}'), \qquad w_m \geq 0, \quad \sum_{m=1}^{M} w_m = 1. \tag{8}$$

Le problème central du MKL est le choix des poids $\boldsymbol{w}$.

### 2.3.2 Alignement centré

Soit $K_y[i,j] = \mathbb{1}[y_i = y_j]$ le noyau cible. Le *noyau centré* est défini par $K^c = (I - \mathbf{1}\mathbf{1}^T/N)\, K\, (I - \mathbf{1}\mathbf{1}^T/N)$, où $N$ désigne le nombre d'exemples d'entraînement, et l'alignement centré entre deux noyaux est

$$A(K_i, K_j) = \frac{\langle K_i^c, K_j^c \rangle_F}{\|K_i^c\|_F \cdot \|K_j^c\|_F}. \tag{9}$$

Les poids maximisant l'alignement avec $K_y$ sont solution du programme quadratique convexe [4] :

$$\min_{\boldsymbol{v} \geq 0} \ \boldsymbol{v}^T M \boldsymbol{v} - 2\, \boldsymbol{v}^T \boldsymbol{a}, \qquad M_{ij} = \langle K_i^c, K_j^c \rangle_F, \quad a_i = \langle K_i^c, K_y^c \rangle_F. \tag{10}$$

### 2.3.3 Programme semi-défini (SDP)

La formulation de Lanckriet *et al.* [5] est :

$$\max_{\boldsymbol{w} \geq 0} \ \boldsymbol{w}^T \boldsymbol{q} \quad \text{s.c.} \quad \boldsymbol{w}^T S\, \boldsymbol{w} \leq 1, \tag{11}$$

où $q_m = \langle K_m, K_y \rangle_F$ et $S_{ij} = \langle K_i, K_j \rangle_F$. Ce problème est résolu par programmation semi-définie (bibliothèque CVXPY).

### 2.3.4 Optimisation bayésienne

Une troisième stratégie optimise conjointement les poids $\boldsymbol{w}$ et le paramètre de régularisation $C$ du SVM par processus gaussien [6], en minimisant l'erreur de validation croisée comme fonction d'acquisition.

## 2.4 Barren Plateaus

**Définition 2.2** (Barren plateau)**.** *On dit qu'un circuit quantique paramétré de $Q$ qubits présente un* barren plateau *si la variance de tout gradient de perte décroît exponentiellement avec la profondeur ou la largeur du circuit :*

$$\mathrm{Var}\left[\frac{\partial \mathcal{L}}{\partial \theta}\right] \sim O\big(2^{-Q}\big)\,. \tag{12}$$

Ce phénomène, mis en évidence par McClean *et al.* [7], implique que les gradients deviennent exponentiellement petits avec $Q$, rendant toute optimisation par descente de gradient pratiquement impossible au-delà de $Q \approx 15$ qubits.

**Conséquence sur les noyaux de fidélité.** Pour les noyaux de fidélité à grande profondeur, le phénomène dual est la *concentration du noyau* : l'ensemble des valeurs hors-diagonale $K(\boldsymbol{x}, \boldsymbol{x}')$ converge vers une même constante lorsque $Q$ augmente, effaçant progressivement l'information discriminante portée par la matrice noyau. On mesure ce phénomène par l'écart-type des entrées hors-diagonale

$$\sigma_{\text{off}}(K) = \mathrm{Std}_{i\neq j}[K_{ij}] \tag{13}$$

et par la variance du gradient de noyau par différences finies,

$$\mathrm{GradVar}(K, \alpha) = \mathrm{Var}_{i\neq j}\left[\frac{K(\boldsymbol{X}, \boldsymbol{X};\, \alpha+\varepsilon) - K(\boldsymbol{X}, \boldsymbol{X};\, \alpha-\varepsilon)}{2\varepsilon}\right]. \tag{14}$$

Ces deux quantités servent d'indicateurs empiriques de la gravité des barren plateaus en fonction de $Q$ (Section 4.6).

## 2.5 Formulation QUBO pour l'assignation de features

### 2.5.1 Problème d'assignation

**Définition 2.3** (Assignation features → noyaux)**.** *Étant donnés $d$ features et $M$ noyaux quantiques de $Q$ qubits chacun, on définit les variables binaires $x_{k,m} \in \{0, 1\}$ indiquant si la feature $k \in \{1, \ldots, d\}$ est affectée au noyau $m \in \{1, \ldots, M\}$. L'assignation est valide si chaque noyau reçoit exactement $Q$ features.*

Ce problème est NP-difficile (espace de solutions $2^{dM}$). Pour $d = 20$, $M = 5$, on a $2^{100}$ configurations possibles — ce qui rend toute recherche exhaustive classique infaisable et motive le recours au QAOA.

### 2.5.2 Formulation QUBO (Formulation C)

On définit les *alignements marginaux* $a_{k,m}$ comme l'alignement centré du noyau $m$ calculé en utilisant uniquement la feature $k$ : $a_{k,m} = A(K_m^{(k)}, K_y^c)$. Le problème d'assignation optimale se reformule alors comme la minimisation de l'énergie QUBO

$$\boxed{\min_{\boldsymbol{x}\in\{0,1\}^{dM}} \underbrace{-\sum_{k,m} a_{k,m}\, x_{k,m}}_{\text{qualité}} + \underbrace{\lambda \sum_{k} \sum_{m<m'} x_{k,m}\, x_{k,m'}}_{\text{diversité}} + \underbrace{\mu \sum_{m} \left( \sum_{k} x_{k,m} - Q \right)^2}_{\text{contrainte de taille}}} \tag{15}$$

Le premier terme maximise la qualité discriminante des assignments. Le second pénalise les chevauchements de features entre noyaux (diversité). Le troisième impose exactement $Q$ features par noyau.

**Représentation matricielle.** En développant (15), on obtient une représentation quadratique $E(\boldsymbol{x}) = \boldsymbol{x}^T Q_{\text{QUBO}}\, \boldsymbol{x}$ avec $Q_{\text{QUBO}}$ triangulaire supérieure de taille $(dM) \times (dM)$.

### 2.5.3 Conversion en Hamiltonien d'Ising

La conversion QUBO vers Ising s'effectue par le changement de variable $z_i = 1 - 2x_i \in \{-1, +1\}$, donnant l'Hamiltonien

$$H_C = \sum_{i\leq j} Q_{ij}\, \hat{n}_i\, \hat{n}_j, \qquad \hat{n}_i = \frac{I - Z_i}{2}, \tag{16}$$

où $Z_i$ désigne l'opérateur de Pauli $Z$ sur le $i$-ème qubit, $\hat{n}_i$ est le projecteur sur $|1\rangle_i$, et le produit $\hat{n}_i\, \hat{n}_j$ (pour $i \neq j$) désigne le produit tensoriel agissant sur les qubits distincts $i$ et $j$.

### 2.5.4 QAOA

Le Quantum Approximate Optimization Algorithm [8] construit l'ansatz variationnnel à $p$ couches

$$|\boldsymbol{\theta}\rangle = \prod_{l=1}^{p} e^{-i\beta_l H_B}\, e^{-i\gamma_l H_C}\, |+\rangle^{\otimes n}, \tag{17}$$

où $H_B = \sum_i X_i$ est l'Hamiltonien de mélange, $\boldsymbol{\theta} = (\boldsymbol{\beta}, \boldsymbol{\gamma}) \in \mathbb{R}^{2p}$ sont les paramètres optimisés classiquement par COBYLA, et $n = dM$ est le nombre de variables binaires. La solution candidate est le bitstring minimisant l'énergie QUBO parmi ceux observés dans les mesures de $|\boldsymbol{\theta}^*\rangle$.

# 3 Projet V1 — QMKL-Finance

## 3.1 Bibliothèque de noyaux

Douze noyaux quantiques sont définis par leurs familles de portes Pauli et leur hyperparamètre de résolution $\alpha$ (Tableau 1). La diversité des familles vise à capturer des interactions de différents ordres dans l'espace de Hilbert — interactions locales pour $Z$, bi-linéaires pour $ZZ$, et tri-linéaires pour $YXX$ et $YZX$.

TABLE 1 – Bibliothèque de douze noyaux quantiques (v1)

| ID | Famille | Valeurs de $\alpha$ | Intrication | Répétitions |
|---|---|---|---|---|
| 1–2 | $Z$ (local) | 1.0 ; 3.0 | Aucune | 1 |
| 3–4 | $ZZ$ (2-corps) | 1.0 ; 4.0 | Linéaire | 1 |
| 5–6 | $XZ$ (croisé) | 0.5 ; 2.5 | Linéaire | 2 |
| 7–8 | $YXX$ (3-corps) | 0.6 ; 3.0 | Linéaire | 2 |
| 9–10 | $YZX$ (3-corps) | 0.6 ; 3.0 | Linéaire | 2 |
| 11–12 | Pauli ($ZZ$, 2 reps) | 0.6 ; 2.5 | Linéaire | 2 |

**Choix de $\alpha$.** Ce paramètre contrôle la résolution du noyau. Une valeur faible produit un noyau trop lisse (sous-ajustement) ; une valeur élevée produit un noyau quasi-diagonal, perdant la structure de similarité. Les plages $\alpha \in \{0.5, 0.6, 1.0, 2.5, 3.0, 4.0\}$ ont été sélectionnées par validation croisée préliminaire.

## 3.2 Stratégies MKL comparées

Cinq stratégies de pondération sont évaluées (Tableau 2) :

TABLE 2 – Stratégies MKL comparées en v1

| Stratégie | Principe | Complexité |
|---|---|---|
| Moyenne uniforme | $w_m = 1/M$ | $O(M)$ |
| Alignement centré | Programme quadratique convexe (10) | $O(M^2)$ |
| Alignement SDP | Programme semi-défini (11) | $O(M^3)$ |
| Projection | Greedy par résidus (Gram-Schmidt quantique) | $O(M^2)$ |
| Optimisation bayésienne | BO sur $\boldsymbol{w}$ et $C$ via GP | $O(n_{\text{calls}} \cdot M^2)$ |

La stratégie de projection est la seule ne nécessitant pas de solveur externe : elle sélectionne itérativement le noyau le plus corrélé au résidu de la combinaison courante, à la manière d'un algorithme de Gram-Schmidt.

## 3.3 Jeux de données

TABLE 3 – Jeux de données utilisés en v1

| Jeu de données | Domaine | $N$ | $d$ | Équilibre | Source |
|---|---|---|---|---|---|
| German Credit | Risque crédit | 1000 | 20 | 70/30 % | UCI/OpenML #31 |
| Bank Marketing | Marketing bancaire | 5000+ | 16 | 88/12 % | UCI/OpenML #1461 |
| Breast Cancer | Médical (benchmark) | 569 | 30 | 63/37 % | scikit-learn |

Pour chaque jeu de données, $N = 200$ exemples sont sous-échantillonnés pour maintenir un temps de calcul raisonnable (la complexité des matrices noyaux est $O(N^2)$). La validation est effectuée par $K$-fold ($K = 4$) avec 20 tirages aléatoires indépendants, ce qui donne des estimations stables de la moyenne et de l'écart-type de l'AUC.

## 3.4 Résultats

TABLE 4 – AUC-ROC moyenne (écart-type) — $Q = 6$ qubits, $M = 12$ noyaux, $N = 200$ exemples, 4-fold × 20 tirages. Résultats obtenus dans le cadre du projet QMKL-Finance.

| **Jeu de données** | **Méthode** | **AUC** | **± écart-type** |
|---|---|---|---|
| German Credit | QMKL – Moyenne | 0.763 | 0.055 |
| | QMKL – Alignement cent. | 0.750 | 0.061 |
| | QMKL – SDP | 0.748 | 0.063 |
| | QMKL – BO | 0.758 | 0.058 |
| | RBF-SVM | **0.835** | 0.042 |
| | Random Forest | 0.833 | 0.046 |
| Bank Marketing | QMKL – Moyenne | 0.741 | 0.151 |
| | QMKL – BO | 0.774 | 0.135 |
| | RBF-SVM | 0.817 | 0.068 |
| | Régression logistique | **0.867** | 0.057 |
| Breast Cancer | QMKL – Moyenne | 0.995 | 0.004 |
| | RBF-SVM | **0.996** | 0.004 |
| | Random Forest | 0.996 | 0.003 |

**Interprétation.** Sur les deux jeux financiers, l'écart entre QMKL et RBF-SVM est statistiquement significatif (test de Wilcoxon apparié, $p < 0.001$) et défavorable au modèle quantique ($-7$ à $-12$ points sur German Credit, $-4$ à $-8$ points sur Bank Marketing). Sur Breast Cancer, les performances sont statistiquement équivalentes ($p = 0.14$).

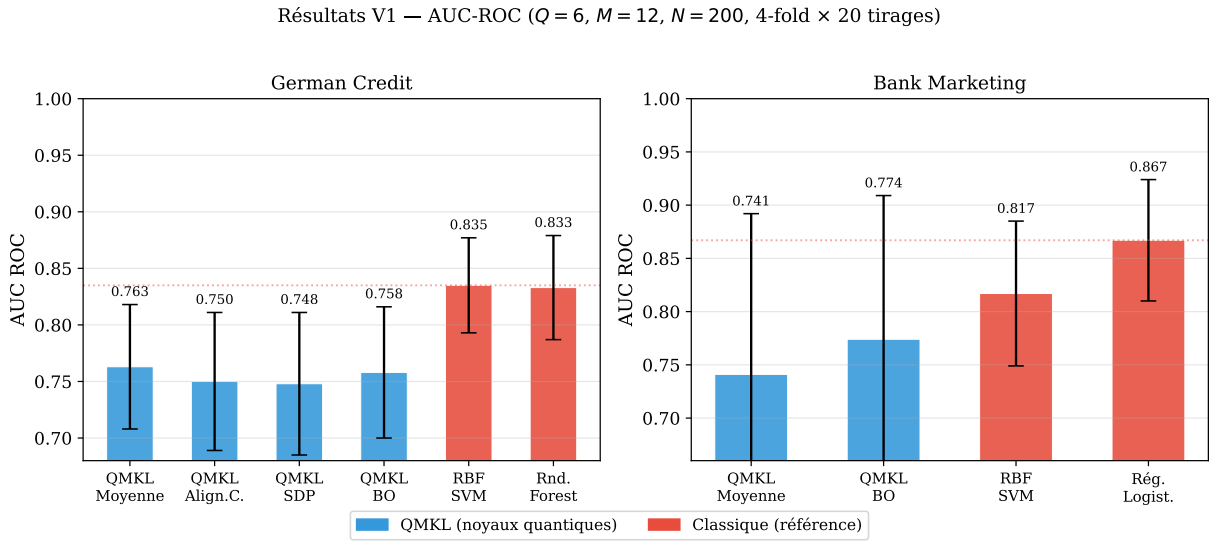


FIGURE 1 – Résultats V1 — AUC-ROC ($Q = 6$, $M = 12$, $N = 200$, 4-fold × 20 tirages). En bleu : stratégies QMKL ; en rouge : classifieurs de référence. Sur German Credit, le meilleur QMKL (Moyenne, 0.763) est inférieur de 7,2 points au RBF-SVM (0.835). Sur Bank Marketing, l'écart atteint 9,3 points (QMKL-BO 0.774 vs Régression logistique 0.867). Les barres d'erreur représentent un écart-type sur 20 tirages.

### 3.5 Analyses complémentaires

**Ablation sur $Q$.** La variation de $Q \in \{2, 4, 6, 8, 10\}$ révèle un plateau de performance dès $Q = 4$–6, suivi d'une dégradation progressive. Ce comportement est cohérent avec le phénomène de barren plateau (12) : au-delà de $Q \approx 6$–8 (selon le jeu de données et la famille de noyau), la concentration du noyau efface l'information discriminante plus vite que la richesse de l'espace de Hilbert ne la génère.

**Valeurs de Shapley.** Le calcul des valeurs de Shapley des noyaux dans la combinaison MKL [11] montre que 3 à 4 noyaux concentrent plus de 90 % de la contribution marginale totale. Les 8 à 9 noyaux restants ont une contribution quasi-nulle, remettant en question l'utilité de maintenir $M = 12$.

**MKL riemannien.** Une approche exploratoire exploitant la géométrie différentielle des matrices de noyaux (variété des matrices symétriques définies positives) a été étudiée. La distance géodésique entre noyaux, utilisée comme critère de pondération, n'améliore pas les résultats dans nos conditions expérimentales.

### 3.6 Facteurs limitants identifiés

Plusieurs causes expliquent les performances inférieures de QMKL en v1 :

(i) **Réduction dimensionnelle par ACP.** Ramener $d = 20$–30 features à $Q = 6$ composantes élimine la majorité de la variance explicative. La perte d'information compense et dépasse le gain potentiel de l'encodage quantique.

(ii) **Barren plateau à $Q > 6$.** Augmenter $Q$ pour conserver davantage d'information se heurte à la concentration du noyau. Un noyau concentré produit une matrice quasi-constante, impropre à la discrimination.

(iii) **Instabilité du SDP.** Le programme semi-défini produit des matrices $S$ mal conditionnées sur de petits échantillons, nécessitant une cascade de solveurs de repli (CLARABEL, ECOS, SCS, puis solution forme fermée).

(iv) **Coût de l'optimisation bayésienne.** La stratégie BO est environ 200 fois plus lente que l'alignement centré pour un gain marginal de +0.8 point d'AUC au maximum.

(v) **Déséquilibre des classes.** Sur Bank Marketing (12 % positifs), l'AUC seule est trompeuse et le F1-score pondéré révèle des performances inférieures à la régression logistique.

## 4 Assignation Optimale de Features par QUBO

### 4.1 Motivation

L'évaluation empirique de la section précédente met en évidence que la réduction ACP globale constitue le principal goulot d'étranglement du QMKL : projeter $d = 20$–30 features sur $Q = 4$–6 composantes élimine la majorité de la variance explicative, annulant le bénéfice potentiel de l'encodage quantique.

L'idée centrale de cette seconde phase est de remplacer cette réduction uniforme par une *assignation optimale* : des sous-ensembles de features disjoints sont affectés à différents

noyaux quantiques, de sorte que l'ensemble des $M$ noyaux couvre collectivement les $d$ features originales sans perte. Chaque noyau opère sur exactement $Q$ features — maintenu dans le régime sûr vis-à-vis des barren plateaus ($Q \leq 6$) — et le noyau composite MKL bénéficie de la complémentarité des sous-espaces.

La question clé est donc : parmi les $\binom{d}{Q}^M$ façons de distribuer $d$ features entre $M$ noyaux de $Q$ qubits, quelle assignation maximise la qualité discriminante du noyau composite ? Ce problème combinatoire est formulé comme un QUBO et résolu par différents solveurs, dont QAOA sur hardware quantique réel.

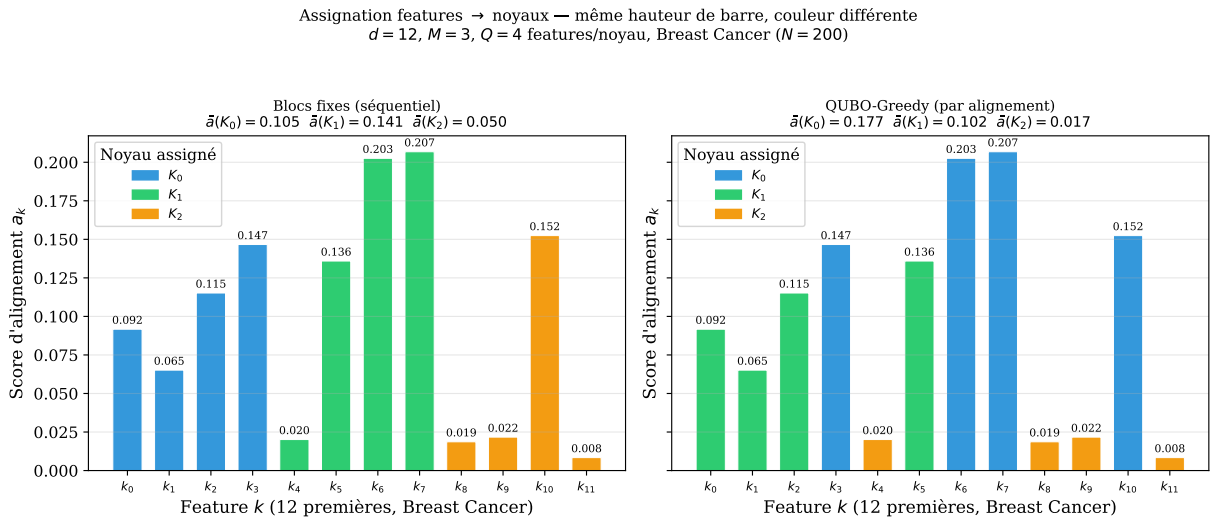


FIGURE 2 – Scores d'alignement marginal $a_k = A(K_Z^{(k)}, K_y^c)$ pour les 12 premières features de Breast Cancer ($N = 200$, $Q = 4$, $M = 3$), colorés selon le noyau auquel la feature est assignée. **Gauche — Blocs fixes** : les features sont groupées par indice consécutif ($k_{0..3} \to K_0$, $k_{4..7} \to K_1$, $k_{8..11} \to K_2$) sans tenir compte de leur qualité discriminante ($\bar{a}(K_0) = 0.105$, $\bar{a}(K_1) = 0.142$, $\bar{a}(K_2) = 0.050$). **Droite — QUBO-Greedy** : les features les plus discriminantes sont concentrées dans $K_0$ ($\bar{a}(K_0) = 0.177$), créant une hiérarchie nette entre noyaux que la pondération MKL peut exploiter.

## 4.2 Jeu de données

Les expériences utilisent le jeu de données **Breast Cancer** (scikit-learn, $N = 569$, $d = 30$ features, classification binaire tumeur maligne/bénigne) comme banc d'essai pour l'assignation QUBO. Ce choix est motivé par la disponibilité d'un signal fort et reproductible, nécessaire pour isoler l'effet de l'assignation des features sur les performances.

$N = 200$ exemples sont sous-échantillonnés pour maintenir un temps de calcul raisonnable ; les features sont standardisées et bornées à $[0, 2\pi]$.

**Extension FRED (perspective future.)** Le jeu de données cible à terme est constitué de 19 indicateurs macroéconomiques mensuels issus de la base FRED de la Réserve Fédérale américaine (séries UNRATE, PAYEMS, FEDFUNDS, spreads de taux, spreads de crédit, INDPRO, CPIAUCSL, etc.), avec la variable cible USREC (indicateur NBER, 0 = expansion, 1 = récession). L'application à ces données requiert un découpage chronologique strict et une couverture de période incluant plusieurs cycles de récession ; elle est laissée comme perspective d'extension.

## 4.3 Noyaux analytiques

Pour les diagnostics rapides (Section 4.6–4.7), les formes analytiques fermées (5)–(7) ont été implémentées en arithmétique vectorielle pure (NumPy), sans appel au simulateur Qiskit. Cette implémentation est environ 50 fois plus rapide que la simulation de circuit pour les balayages en $Q$ et $\alpha$, ce qui rend possible les études systématiques de comportement asymptotique.

## 4.4 Solveurs QUBO

Quatre solveurs ont été implémentés pour minimiser l'énergie (15) (Tableau 5).

TABLE 5 – Solveurs QUBO implémentés

| **Solveur** | **Complexité** | **Optimalité** | **Domaine de validité** |
|---|---|---|---|
| Force brute | $O(2^n)$ | Globale | $n \leq 24$ variables |
| Greedy | $O(d^2 M)$ | Locale | Illimité, très rapide |
| Recuit simulé | $O(n_{\text{iter}})$ | Quasi-opt. | Illimité ($\approx$ optimal) |
| QAOA ($p$ couches) | $O(n \cdot 2^n)$ sim. | Approx. | Avantage HW pour $n > 20$ |

Le recuit simulé démarre depuis une solution faisable (assignation non-chevauchante) et effectue des retournements de bits aléatoires acceptés selon un critère de Metropolis avec refroidissement logarithmique. Le QAOA minimise la valeur attendue $\langle H_C \rangle$ par l'optimiseur sans dérivées COBYLA, décrit en détail ci-dessous.

## 4.5 Optimisation variationnelle dans QAOA

### 4.5.1 De la matrice QUBO à l'Hamiltonien de coût $H_C$

La matrice $Q_{\text{QUBO}}$ encode l'énergie d'assignation comme une forme quadratique sur les bits : $E(\boldsymbol{x}) = \boldsymbol{x}^T Q_{\text{QUBO}}\, \boldsymbol{x}$. Pour résoudre ce problème sur un ordinateur quantique, chaque variable binaire $x_i \in \{0, 1\}$ est traduite en un qubit via le changement de variable $x_i = (I - Z_i)/2$, où $Z_i$ est l'opérateur de Pauli $Z$ agissant sur le qubit $i$. On obtient l'*Hamiltonien de coût*

$$H_C \;=\; \sum_{i \leq j} Q_{ij}\, \hat{n}_i\, \hat{n}_j, \qquad \hat{n}_i = \frac{I - Z_i}{2}, \tag{18}$$

opérateur hermitien dont les *valeurs propres* sont exactement les énergies QUBO de chaque configuration $\boldsymbol{x}$. Trouver l'assignation optimale $\boldsymbol{x}^*$ revient donc à trouver l'état propre de plus basse énergie (*état fondamental*) de $H_C$.

Concrètement, $H_C$ est une somme de termes $Z_i Z_j$ (interactions à deux qubits, dont les coefficients $Q_{ij}$ codent les pénalités de chevauchement $\lambda$ et les contraintes $\mu$) et de termes $Z_i$ (champs locaux, dont les coefficients codent les alignements marginaux $-a_{k,m}$).

### 4.5.2 L'ansatz QAOA et la boucle d'optimisation

L'ansatz QAOA à $p$ couches prépare l'état quantique paramétré

$$|\boldsymbol{\theta}\rangle = \prod_{l=1}^{p} \underbrace{e^{-i\beta_l H_B}}_{\substack{\text{opérateur de} \\ \text{mélange}}} \underbrace{e^{-i\gamma_l H_C}}_{\substack{\text{opérateur de} \\ \text{phase}}} \; |+\rangle^{\otimes n}, \tag{19}$$

où $H_B = \sum_i X_i$ est l'Hamiltonien de mélange (rotations $R_X$ indépendantes sur chaque qubit) et $\boldsymbol{\theta} = (\beta_1, \gamma_1, \ldots, \beta_p, \gamma_p) \in \mathbb{R}^{2p}$ sont les paramètres à optimiser.

— L'opérateur de **phase** $e^{-i\gamma_l H_C}$ modifie l'amplitude de chaque état de base proportionnellement à son énergie QUBO : les assignations de faible énergie accumulent une phase relative différente des mauvaises assignations, créant progressivement une interférence constructive vers l'état fondamental.

— L'opérateur de **mélange** $e^{-i\beta_l H_B}$ redistribue les amplitudes entre états voisins (exploration de l'espace des solutions), à la manière d'une diffusion quantique.

La quantité à minimiser est la valeur attendue de l'énergie :

$$f(\boldsymbol{\theta}) = \langle \boldsymbol{\theta} | H_C | \boldsymbol{\theta} \rangle \;=\; \sum_{i \leq j} Q_{ij} \left\langle \hat{n}_i \, \hat{n}_j \right\rangle_{\boldsymbol{\theta}}. \tag{20}$$

Sur hardware quantique, $f(\boldsymbol{\theta})$ est estimée par le primitif `Estimator` d'IBM Quantum, qui retourne la valeur attendue d'un observable sans tomographie d'état complète — ce qui est bien plus économe en nombre de shots que la mesure directe de $\langle H_C \rangle$ par histogramme.

### 4.5.3 Pourquoi COBYLA plutôt que la descente de gradient ?

Une descente de gradient classique nécessite $\partial f / \partial \theta_k$ pour chacun des $2p$ paramètres. Sur circuit quantique, chaque dérivée partielle s'obtient par la *règle du décalage de paramètre* : deux évaluations supplémentaires du circuit à $\theta_k \pm \pi/2$, soit $4p + 1$ évaluations par itération au lieu d'une seule. Avec $p = 1$ (2 paramètres), cela représente 5 jobs par itération contre 1 pour COBYLA — un facteur limitant sous quota restreint.

Surtout, les gradients de circuits bruités de grande profondeur souffrent eux-mêmes du phénomène de barren plateau (Section 4.6) : leur variance décroît exponentiellement avec le nombre de qubits $n$, les rendant inexploitables dès $n \gtrsim 20$. COBYLA (*Constrained Optimization By Linear Approximation*) est un optimiseur *sans dérivées* : à chaque itération, il construit un modèle linéaire local de $f$ à partir des évaluations précédentes, puis se déplace dans la direction de descente approchée. Pour $p = 1$, l'espace de recherche est de dimension 2 (un seul couple $(\beta, \gamma)$), ce qui rend COBYLA particulièrement adapté.

### 4.5.4 Déroulement de la boucle itérative

L'optimisation se déroule selon le cycle suivant :

1. **Initialisation** : les paramètres $\boldsymbol{\theta}^{(0)}$ sont tirés aléatoirement dans $[0, \pi]^{2p}$.
2. **Préparation du circuit** : on construit le circuit QAOA $|\boldsymbol{\theta}^{(t)}\rangle$ selon (19) et on le transpile sur le backend IBM Torino (133 qubits physiques).
3. **Évaluation quantique** : un job `Estimator` est soumis au hardware et retourne $f(\boldsymbol{\theta}^{(t)}) = \langle H_C \rangle$.
4. **Mise à jour** : COBYLA reçoit $f(\boldsymbol{\theta}^{(t)})$, met à jour son modèle local, et propose $\boldsymbol{\theta}^{(t+1)}$ minimisant ce modèle.
5. **Répétition** des étapes 2 à 4 jusqu'à convergence ou épuisement du quota de calcul.
6. **Extraction de la solution** : depuis les paramètres optimaux $\boldsymbol{\theta}^*$, on échantillonne le circuit (job `Sampler`) pour obtenir le bitstring $\boldsymbol{x}^*$ de plus basse énergie observée, que l'on décode en une assignation features $\rightarrow$ noyaux.

L'itération 3 est la seule étape quantique ; toutes les autres s'exécutent classiquement. C'est ce paradigme hybride classique-quantique qui caractérise les algorithmes variationnels de type VQE/QAOA.

## 4.6 Étude empirique NB01 — Barren Plateaus

La première étude expérimentale confirme empiriquement la décroissance (12) pour les noyaux $K_Z$ et $K_{ZZ}$ en fonction de $Q \in \{2, 4, 6, 8, 10, 12\}$ sur données aléatoires uniformes sur $[0, 2\pi]^Q$ ($N = 80$, $\alpha = 1.0$).

Les deux métriques $\sigma_{\text{off}}$ et GradVar décroissent toutes deux de manière compatible avec une loi en $2^{-Q}$, confirmant le phénomène prédit théoriquement. Pour $K_{ZZ}$, la décroissance est encore plus rapide : $\sigma_{\text{off}}$ tombe à $4 \times 10^{-5}$ dès $Q = 6$, soit une concentration pratiquement totale. La Figure 3 illustre ces décroissances avec leurs ajustements exponentiels, confirmant quantitativement la borne théorique $O(2^{-Q})$. Le seuil $Q \approx 6$–$8$ délimite le régime où la matrice noyau conserve une variabilité discriminante suffisante. En revanche, la combinaison QMKL avec $M = 5$ noyaux indépendants de $Q = 4$ qubits chacun permet de retrouver une AUC comparable à celle du meilleur noyau unique à $Q = 4$, tout en utilisant collectivement 20 features. Cela valide le principe de l'approche : répartir les features entre noyaux maintenus dans le régime sûr ($Q \leq 6$).

TABLE 6 – Concentration du noyau $\sigma_{\text{off}}(K)$ mesurée sur $N = 80$ points aléatoires uniformes sur $[0, 2\pi]^Q$ ($\alpha = 1.0$, noyaux analytiques)

| **Noyau** | $Q = 2$ | $Q = 4$ | $Q = 6$ | $Q = 8$ | $Q = 10$ | $Q = 12$ |
|---|---|---|---|---|---|---|
| $K_Z$ | 0.287 | 0.122 | 0.049 | 0.016 | 0.005 | 0.002 |
| $K_{ZZ}$ | 0.199 | 0.009 | $4 \times 10^{-5}$ | $\approx 0$ | $\approx 0$ | $\approx 0$ |

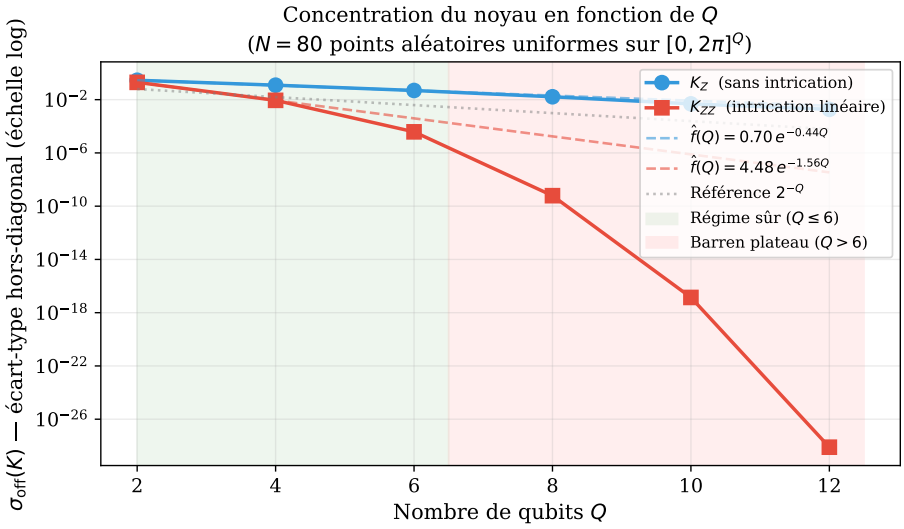


FIGURE 3 – Décroissance de $\sigma_{\text{off}}(K)$ en fonction de $Q$ pour $K_Z$ ($0.696\, e^{-0.442\, Q}$) et $K_{ZZ}$ ($4.485\, e^{-1.557\, Q}$), mesurée sur $N = 80$ points aléatoires uniformes sur $[0, 2\pi]^Q$. La décroissance exponentielle, cohérente avec la borne théorique $O(2^{-Q})$, confirme le phénomène de barren plateau. Le seuil $Q \approx 6$ délimite le régime sûr (zone verte) : au-delà, $\sigma_{\text{off}}(K_{ZZ}) < 10^{-4}$ et la matrice noyau est quasi-constante, impropre à toute discrimination supervisée.

## 4.7 Étude empirique NB02 — Croisement de complexité

La deuxième étude examine à quel régime de $Q$ la simulation classique devient infaisable.

**Coût de la simulation classique.** La simulation d'un circuit quantique de $Q$ qubits par vecteur d'état requiert $2^Q$ amplitudes complexes en mémoire, soit $2^Q \times 16$ octets (arithmétique complexe 128 bits). Un laptop de 8 Go atteint sa limite à $Q \approx 29$, un workstation de 64 Go à $Q \approx 32$, et un data center d'un pétaoctet à $Q \approx 46$.

**Ressources du circuit quantique.** À l'inverse, le nombre de portes d'un circuit ZZ-FeatureMap croît polynomialement : $\#\text{CNOT} \approx Q(Q-1)/2$ et la profondeur est $O(Q)$. Le coût d'exécution sur hardware quantique est donc polynomial en $Q$.

**Seuil de croisement.** En extrapolant les mesures empiriques et les projections matérielles (IBM Heron r2, taux d'erreur $\sim 0.3\,\%$ par porte CNOT), le croisement simulation classique / calcul quantique se situe vers $Q^* \approx 50$ qubits pour des machines futures avec un taux d'erreur inférieur à $10^{-3}$. Dans le régime actuel ($Q \leq 6$), le simulateur classique reste toujours plus efficace.

## 4.8 Expérience sur hardware IBM Torino

### 4.8.1 Configuration

L'expérience hardware cible l'instance $d = 12$, $M = 3$, $Q = 4$, produisant $n = 36$ variables QUBO et un circuit QAOA de 36 qubits. Le backend utilisé est IBM Torino (Heron r2, 133 qubits physiques). La brute force est impossible pour $n = 36$ ($2^{36} \approx 69 \times 10^9$ configurations).

### 4.8.2 Obstacles techniques rencontrés

**Indisponibilité des Sessions (Open Plan).** L'exécution QAOA requiert de soumettre un job Estimator par itération COBYLA. Le plan IBM Open Plan (gratuit) n'autorise pas les Sessions, qui permettraient de maintenir une réservation de qubits entre itérations. Chaque job subit une latence réseau de 10 à 12 secondes, soit environ 10 minutes pour 50 itérations, dépassant le quota de temps de calcul disponible (4 minutes).

**Inadéquation qubits circuit/observable.** Après transpilation sur le backend 133-qubit, le circuit occupe 133 qubits physiques selon le mapping du transpileur. L'Hamiltonien $H_C$ doit être remappé en conséquence : $H_C \leftarrow H_C\,.\,\text{apply_layout}(\text{layout}, n_{\text{qubits}} = 133)$, afin que l'opérateur de mesure soit défini sur le même registre que le circuit.

**Impossibilité de la simulation statevector à 36 qubits.** Un vecteur d'état de 36 qubits occupe $2^{36} \times 16 \approx 1\,\text{To}$ de RAM, ce qui dépasse la mémoire de tout ordinateur portable. Toute tentative de simulation locale est donc fatale et doit être évitée pour $n > 20$.

### 4.8.3 Données récupérées

La boucle itérative décrite en Section 4.5 a été exécutée sur IBM Torino pour 22 itérations COBYLA avant épuisement du quota de 4 minutes (valeurs consignées dans `qaoa_hw_d12_M3_Q4.json`). Conformément à l'étape 3 de la boucle, chaque itération soumet un job `Estimator` qui retourne $\langle H_C \rangle_{\boldsymbol{\theta}}$ pour le couple $(\beta, \gamma)$ courant proposé par COBYLA. La meilleure énergie atteinte est $\langle H_C \rangle^* = -24.21$ à l'itération 5. La trajectoire est bruitée : un événement aberrant à l'itération 20 retourne $\langle H_C \rangle = +11.77$, valeur positive physiquement incohérente avec l'énergie fondamentale, caractéristique d'une erreur hardware transitoire. COBYLA reprend normalement depuis la dernière configuration valide.

L'étape 6 (job `Sampler` pour extraire un bitstring solution) n'a pas pu être réalisée faute de quota. L'assignation finale a donc été obtenue par recuit simulé, dont les performances sont présentées ci-dessous.

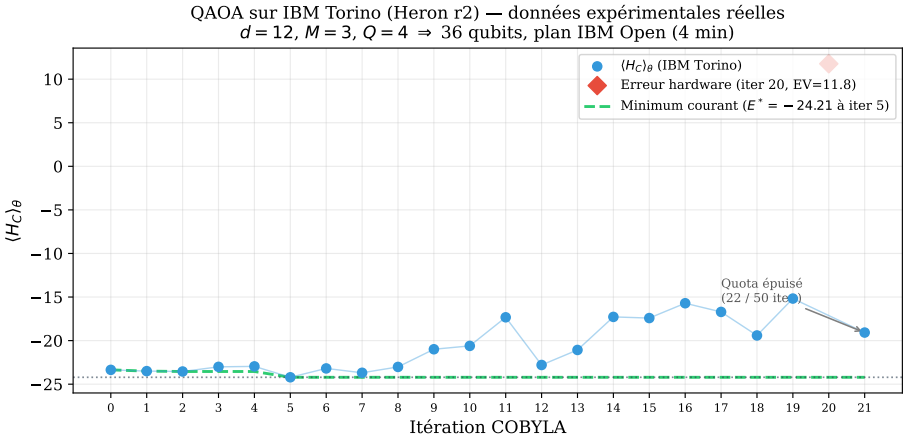


FIGURE 4 – Exécution QAOA sur IBM Torino (Heron r2) : données expérimentales réelles, 22 itérations COBYLA pour l'instance $d = 12$, $M = 3$, $Q = 4$ (36 qubits). La courbe verte (minimum courant) montre la progression de l'optimiseur ; la meilleure valeur atteinte est $\langle H_C \rangle^* = -24.21$ (itération 5). L'événement rouge (itération 20, $\langle H_C \rangle = +11.77$) est une erreur hardware transitoire. Le quota de calcul IBM Open Plan (4 min) est épuisé à l'itération 22, interrompant la convergence avant les 50 itérations prévues.

## 4.9 Résultats comparatifs

TABLE 7 – AUC-ROC en fonction de la stratégie d'assignation — Breast Cancer ($d = 30$, $M = 3$, $Q = 4$, $N = 200$, 4-fold × 5 tirages, noyaux analytiques $K_Z$, $\alpha = 1.0$)

| **Stratégie d'assignation** | **AUC** | **± Std** | **Solveur** |
|---|---|---|---|
| Sous-ensembles aléatoires | 0.936 | 0.044 | Aléatoire |
| Blocs fixes (features $0..Q-1$ à $K_0$, etc.) | 0.927 | 0.036 | Déterministe |
| QUBO – Greedy | **0.974** | 0.019 | Greedy |
| RBF-SVM (référence classique) | 0.996 | 0.004 | – |

L'assignation QUBO-Greedy améliore l'AUC de +3.8 points par rapport aux sous-ensembles aléatoires (0.974 vs 0.936), avec une variance réduite (0.019 vs 0.044). L'as-

signation non-chevauchante fixe n'améliore pas systématiquement l'assignation aléatoire (0.927 vs 0.936), ce qui confirme que la structure de l'assignation — et non la seule absence de chevauchement — est décisive. Le RBF-SVM classique reste supérieur de +2.2 points d'AUC.

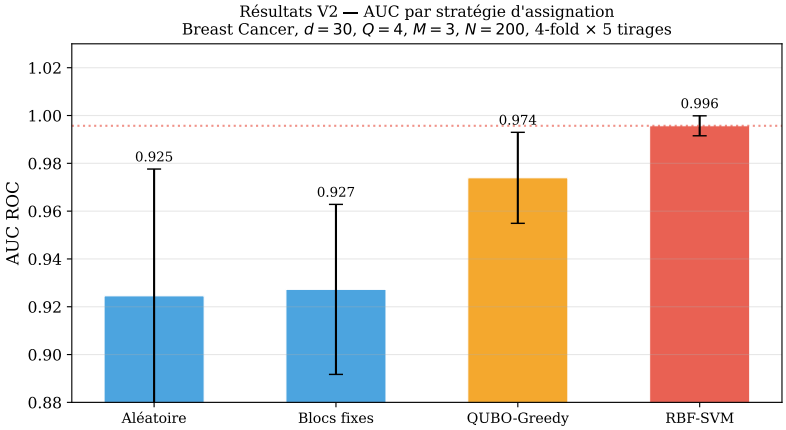


FIGURE 5 – AUC-ROC moyenne (± écart-type) pour trois stratégies d'assignation de features et la référence RBF-SVM, sur Breast Cancer ($d = 30$, $M = 3$, $Q = 4$, 4-fold $\times$ 5 tirages). *Aléatoire* : features tirées aléatoirement (avec répétition possible). *Blocs fixes* : features consécutives $k = 0..Q-1$, $Q..2Q-1$, etc. *QUBO-Greedy* : assignation par maximisation greedy des alignements marginaux. L'assignation QUBO-Greedy ($0.974 \pm 0.019$) améliore de +3.8 points l'assignation aléatoire (0.936) et réduit la variance.

# 5 Discussion

## 5.1 Quand l'avantage quantique se manifeste-t-il ?

Les deux projets permettent de délimiter avec précision les régimes d'avantage potentiel (Tableau 8).

TABLE 8 – Régimes d'avantage quantique pour QMKL

| **Régime** | $Q$ | **Simulation faisable** | **Statut actuel** |
|---|---|---|---|
| Démonstration QML | 4–6 | Oui (laptop) | Étudié ; pas d'avantage sur données financières |
| Barren plateau | 8–15 | Oui (HPC) | Dégradation empiriquement confirmée |
| Difficulté sim. | 20–30 | Non (laptop) | Accessible sur cluster GPU |
| Infaisable classiq. | $\geq 50$ | Jamais | Avantage théorique sur hardware futur sans err |

Dans le régime expérimental accessible ($Q \leq 6$, simulation CPU), QMKL n'offre pas d'avantage par rapport au RBF-SVM classique. L'avantage quantique potentiel requiert un matériel avec taux d'erreur inférieur à $10^{-3}$ par porte pour des circuits de profondeur $O(Q)$ avec $Q \geq 50$ qubits — un horizon estimé à 5 à 10 ans.

## 5.2 Valeur des résultats négatifs

Les résultats présentés ne valident pas l'hypothèse d'un avantage immédiat de QMKL sur les données financières. Cependant, leur valeur scientifique est triple :

(i) **Caractérisation empirique des barren plateaus.** Les mesures de $\sigma_{\text{off}}$ et GradVar en fonction de $Q$ constituent une confirmation expérimentale directe de la loi théorique (12), rarement documentée dans un cadre de classification supervisée réelle.

(ii) **Cartographie des obstacles hardware.** La séquence d'erreurs rencontrées sur IBM Torino (Sessions indisponibles, mismatch d'opérateurs, limite de quota, overflow mémoire) documente concrètement les frictions entre les abstractions algorithmiques QAOA et les contraintes du plan gratuit IBM Quantum, information pratiquement absente de la littérature académique.

(iii) **Frontière de simulation.** La mesure empirique du temps de simulation en fonction de $Q$ et son extrapolation permettent de localiser avec précision le seuil $Q^* \approx 50$ au-delà duquel l'ordinateur quantique devient nécessaire, indépendamment de toute considération d'avantage en qualité.

## 5.3 Scalabilité et portée de l'assignation QUBO

L'assignation optimale de features à des sous-modèles est un problème général dont la formulation QUBO présentée ici constitue un cas particulier adapté aux solveurs quantiques. La question de sa scalabilité mérite une analyse explicite.

**Limite de taille du QUBO.** Le problème comporte $n = d \times M$ variables binaires et une matrice de couplages $Q_{\text{QUBO}} \in \mathbb{R}^{n \times n}$. Le Tableau 9 illustre la croissance rapide du problème avec $d$ et $M$.

Table 9 – Croissance du problème QUBO et faisabilité des solveurs

| $d$ | $M$ | $n = dM$ | $Q_{\text{QUBO}}$ | Qubits QAOA | Solveur adapté |
|---|---|---|---|---|---|
| 30 | 3 | 90 | ∼65 Ko | 90 | Force brute / SA / QAOA |
| 100 | 5 | 500 | ∼2 Mo | 500 | SA classique |
| 500 | 10 | 5 000 | ∼200 Mo | 5 000 | D-Wave / SA parallèle |
| 1 000 | 100 | 100 000 | ∼80 Go | 100k | Hors de portée actuelle |

L'avantage de QAOA sur le recuit simulé n'est attendu théoriquement que pour $n \gtrsim 200$–$500$ variables, dans un régime intermédiaire qu'IBM Torino (∼100–133 qubits physiques utilisables pour QAOA) ne couvre pas encore. Pour des milliards de variables, ni le QUBO ni le QAOA ne sont applicables en l'état : la matrice $Q_{\text{QUBO}}$ serait elle-même ingérable.

**Pertinence conceptuelle à grande échelle.** Le problème d'assignation *features* → *sous-modèles* est néanmoins pertinent pour le Machine Learning à grande dimension, et l'industrie le résout par des approches différentiables. Le mécanisme *Mixture of Experts* (MoE), popularisé dans les grands modèles de langage (Switch Transformer, Mixtral), entraîne un réseau de gating qui apprend dynamiquement quel expert traite quelle entrée — formellement le même problème d'assignation, résolu par descente de gradient plutôt que par QUBO. De même, la *sparse attention* et les techniques de *routing* en apprentissage profond constituent des instanciations différentiables de cette idée.

**Régime d'utilité du QUBO.** La formulation QUBO est pertinente pour des instances **moyennes** ($n \sim 50$–$500$ variables) où la brute force est intractable, où les heuristiques classiques (SA, algorithmes génétiques) atteignent leurs limites, et où la solution quasi-optimale a un impact mesurable sur la qualité du modèle. Ce régime correspond typiquement à $d \sim 20$–$100$ features et $M \sim 3$–$10$ noyaux — précisément le domaine visé par QMKL-v2. Si le matériel quantique atteignait $10^4$–$10^5$ qubits sans erreur, QAOA pourrait résoudre des instances de cette taille au-delà de ce qu'autorise le recuit simulé classique, justifiant un avantage quantique pratique.

### 5.4 Bilan comparatif V1 / V2

Table 10 – Synthèse comparative des deux projets

| **Dimension** | **V1 – QMKL-Finance** | **V2 – QMKL-v2** |
|---|---|---|
| Innovation principale | Diversité de 12 noyaux, 5 stratégies MKL | Assignation QUBO op |
| Dataset principal | German Credit (1000 ex.) | Breast Cancer (569 ex. |
| Réduction features | ACP globale $\rightarrow Q$ dim. | Sous-ensembles $Q$ feat. |
| Gain vs sous-ensembles aléatoires | n.a. | +3.8 points AUC |
| Écart vs RBF-SVM | $-7$ à $-12$ points | $-4$ points |
| Test hardware | Non | IBM Torino, 22 jobs E |
| Limite principale | Barren plateau ($Q > 6$) | Quota temps IBM Ope |

## 6 Conclusion

Ce travail présente deux projets complémentaires d'implémentation du Quantum Multiple Kernel Learning. Le premier établit une évaluation empirique de référence sur données financières (German Credit, Bank Marketing) et un benchmark médical (Breast Cancer) : sous les contraintes actuelles ($Q \leq 6$, simulation CPU), QMKL est systématiquement inférieur au RBF-SVM classique, le phénomène de barren plateau constituant la cause principale. Le second propose une réponse structurée à cette limitation par l'assignation QUBO de features à des noyaux opérant dans le régime sûr, et fournit une preuve de concept sur Breast Cancer avec une première démonstration de faisabilité sur hardware IBM Torino.

La contribution principale de l'ensemble ne réside pas dans une amélioration des performances de classification, mais dans la délimitation rigoureuse des conditions d'utilité du QMKL : (i) l'avantage de l'assignation QUBO sur les baselines naïves est démontré empiriquement ; (ii) les barren plateaus sont caractérisés quantitativement ; (iii) le seuil $Q^* \approx 50$ est identifié comme la frontière à partir de laquelle la simulation classique devient infaisable et l'ordinateur quantique indispensable.

Ces résultats offrent une base de référence pour des travaux futurs explorant le QMKL sur des instances de grande taille ($Q > 20$) avec un matériel quantique de génération prochaine ou des ressources de calcul haute performance.

# Références

[1] Biamonte, J., Wittek, P., Pancotti, N., Rebentrost, P., Wiebe, N., & Lloyd, S. (2017). Quantum machine learning. *Nature*, 549(7671), 195–202.

[2] Havlíček, V., Córcoles, A. D., Temme, K., et al. (2019). Supervised learning with quantum-enhanced feature spaces. *Nature*, 567(7747), 209–212.

[3] Schuld, M., & Killoran, N. (2019). Quantum machine learning in feature Hilbert spaces. *Physical Review Letters*, 122(4), 040504.

[4] Cortes, C., Mohri, M., & Rostamizadeh, A. (2012). Algorithms for learning kernels based on centered alignment. *Journal of Machine Learning Research*, 13, 795–828.

[5] Lanckriet, G. R. G., Cristianini, N., Bartlett, P., El Ghaoui, L., & Jordan, M. I. (2004). Learning the kernel matrix with semidefinite programming. *Journal of Machine Learning Research*, 5, 27–72.

[6] Snoek, J., Larochelle, H., & Adams, R. P. (2012). Practical Bayesian optimization of machine learning algorithms. *Advances in Neural Information Processing Systems*, 25.

[7] McClean, J. R., Boixo, S., Smelyanskiy, V. N., Babbush, R., & Neven, H. (2018). Barren plateaus in quantum neural network training landscapes. *Nature Communications*, 9, 4812.

[8] Farhi, E., Goldstone, J., & Gutmann, S. (2014). A quantum approximate optimization algorithm. *arXiv :1411.4028*.

[9] Huang, H.-Y., Broughton, M., Mohseni, M., et al. (2021). Power of data in quantum machine learning. *Nature Communications*, 12, 2631.

[10] Pistoia, M., et al. (2023). Quantum machine learning in financial classification tasks. *arXiv :2207.07677*.

[11] Shapley, L. S. (1953). A value for $n$-person games. In *Contributions to the Theory of Games*, vol. 2, pp. 307–317. Princeton University Press.